

# Notas del Curso de Estadística

Carlos E. Martínez Rodríguez

19 de septiembre de 2019

## Estimación por intervalos

Para la media

Intervalos de confianza sobre la varianza

Intervalos de confianza para proporciones

## Intervalos de confianza para dos muestras

Varianzas conocidas

Varianzas desconocidas

$$\sigma_1^2 = \sigma_2^2 = \sigma$$

$$\sigma_1^2 \neq \sigma_2^2$$

## Intervalos de confianza para Distribuciones pareadas

Preliminares

Introducción

Gráfico y Lectura de Datos

Estadística Descriptiva

Intervalos de Confianza y Pruebas de Hipótesis

Análisis de Regresión Lineal

Estadística Multivariada

Anexo 1: Simulación de Variables Aleatorias



- Distribución Uniforme
- Distribución Normal
- Distribución Gamma
- Distribución Beta
- Distribución Exponencial
- Distribución *t*-Student
- Distribución  $\chi^2$
- Distribución Binomial
- Distribución Geométrica
- Distribución Poisson
- Miscelánea de instrucciones

# Intervalos de confianza para $\mu$

Recordemos que  $S^2$  es un estimador insesgado de  $\sigma^2$

## Definición

Sean  $\hat{\theta}_1$  y  $\hat{\theta}_2$  dos estimadores insesgados de  $\theta$ , parámetro poblacional. Si  $\sigma_{\hat{\theta}_1}^2 < \sigma_{\hat{\theta}_2}^2$ , decimos que  $\hat{\theta}_1$  es un estimador más eficaz de  $\theta$  que  $\hat{\theta}_2$ .

Algunas observaciones que es preciso realizar

- Para poblaciones normales,  $\bar{X}$  y  $\tilde{X}$  son estimadores insesgados de  $\mu$ , pero con  $\sigma_{\bar{X}}^2 < \sigma_{\tilde{X}}^2$ .
- Para las estimaciones por intervalos de  $\theta$ , un intervalo de la forma  $\hat{\theta}_L < \theta < \hat{\theta}_U$ ,  $\hat{\theta}_L$  y  $\hat{\theta}_U$  dependen del valor de  $\hat{\theta}$ .
- Para  $\sigma_{\bar{X}}^2 = \frac{\sigma^2}{n}$ , si  $n \rightarrow \infty$ , entonces  $\hat{\theta} \rightarrow \mu$ .

# Intervalos de confianza para $\mu$

- d) Para  $\hat{\theta}$  se determinan  $\hat{\theta}_L$  y  $\hat{\theta}_U$  de modo tal que

$$P \left\{ \hat{\theta}_L < \hat{\theta} < \hat{\theta}_U \right\} = 1 - \alpha, \quad (1)$$

con  $\alpha \in (0, 1)$ . Es decir,  $\theta \in (\hat{\theta}_L, \hat{\theta}_U)$  es un intervalo de confianza del  $100(1 - \alpha)\%$ .

- e) De acuerdo con el TLC se espera que la distribución muestral de  $\bar{X}$  se distribuya aproximadamente normal con media  $\mu_{\bar{X}} = \mu$  y desviación estándar  $\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$ .

# Intervalos de confianza para $\mu$

Para  $Z_{\alpha/2}$  se tiene  $P\{-Z_{\alpha/2} < Z < Z_{\alpha/2}\} = 1 - \alpha$ , donde  $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$ . Entonces  $P\left\{-Z_{\alpha/2} < \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} < Z_{\alpha/2}\right\} = 1 - \alpha$  es equivalente a  $P\left\{\bar{X} - Z_{\alpha/2} \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + Z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right\} = 1 - \alpha$

- f) Si  $\bar{X}$  es la media muestral de una muestra de tamaño  $n$  de una población con varianza conocida  $\sigma^2$ , el intervalo de confianza de  $100(1 - \alpha)\%$  para  $\mu$  es  
$$\mu \in \left(\bar{x} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right).$$
- g) Para muestras pequeñas de poblaciones no normales, no se puede esperar que el grado de confianza sea preciso.
- h) Para  $n \geq 30$ , con distribución de forma no muy sesgada, se pueden tener buenos resultados.

# Intervalos de confianza para $\mu$

## Teorema

Si  $\bar{X}$  es un estimador de  $\mu$ , podemos tener  $100(1 - \alpha)\%$  de confianza en que el error no excederá a  $z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$ , error entre  $\bar{X}$  y  $\mu$ .

## Teorema

Si  $\bar{X}$  es un estimador de  $\mu$ , podemos tener  $100(1 - \alpha)\%$  de confianza en que el error no excederá una cantidad  $e$  cuando el tamaño de la muestra es

$$n = \left( \frac{z_{\alpha/2}\sigma}{e} \right)^2.$$

## Nota

Para intervalos unilaterales

$$P \left\{ \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} < Z_\alpha \right\} = 1 - \alpha$$

# Intervalos de confianza para $\mu$

equivalentemente

$$P \left\{ \mu < \bar{X} + Z_\alpha \frac{\sigma}{\sqrt{n}} \right\} = 1 - \alpha.$$

Si  $\bar{X}$  es la media de una muestra aleatoria de tamaño  $n$  a partir de una población con varianza  $\sigma^2$ , los límites de confianza unilaterales del  $100(1 - \alpha)$  % de confianza para  $\mu$  están dados por

- ▶ Límite unilateral superior:  $\bar{x} + z_\alpha \frac{\sigma}{\sqrt{n}}$
- ▶ Límite unilateral inferior:  $\bar{x} - z_\alpha \frac{\sigma}{\sqrt{n}}$

# Intervalos de confianza para $\mu$

- ▶ Para  $\sigma$  desconocida recordar que  $T = \frac{\bar{X} - \mu}{s/\sqrt{n}} \sim t_{n-1}$ , donde  $s$  es la desviación estándar de la muestra. Entonces

$$P\left\{-t_{\alpha/2} < T < t_{\alpha/2}\right\} = 1 - \alpha, \text{ equivalentemente}$$

$$P\left\{\bar{X} - t_{\alpha/2} \frac{s}{\sqrt{n}} < \mu < \bar{X} + t_{\alpha/2} \frac{s}{\sqrt{n}}\right\} = 1 - \alpha.$$

- ▶ Un intervalo de confianza del  $100(1 - \alpha)$  % de confianza para  $\mu$ ,  $\sigma^2$  desconocida y población normal es  
 $\mu \in \left(\bar{X} - t_{\alpha/2} \frac{s}{\sqrt{n}}, \bar{X} + t_{\alpha/2} \frac{s}{\sqrt{n}}\right)$ , donde  $t_{\alpha/2}$  es una  $t$ -student con  $\nu = n - 1$  grados de libertad.
- ▶ Los límites unilaterales para  $\mu$  con  $\sigma$  desconocida son  $\bar{X} - t_{\alpha/2} \frac{s}{\sqrt{n}}$  y  $\bar{X} + t_{\alpha/2} \frac{s}{\sqrt{n}}$ .

# Intervalos de confianza para $\mu$

- ▶ Cuando la población no es normal,  $\sigma$  desconocida y  $n \geq 30$ ,  $\sigma$  se puede reemplazar por  $s$  para obtener el intervalo de confianza para muestras grandes:

$$\bar{X} \pm t_{\alpha/2} \frac{s}{\sqrt{n}}.$$

- ▶ El estimador de  $\bar{X}$  de  $\mu$ ,  $\sigma$  desconocida, la varianza de  $\sigma_{\bar{X}}^2 = \frac{\sigma^2}{n}$ , el error estándar de  $\bar{X}$  es  $\sigma/\sqrt{n}$ .
- ▶ Si  $\sigma$  es desconocida y la población es normal,  $s \rightarrow \sigma$  y se incluye el error estándar  $s/\sqrt{n}$ , entonces

$$\bar{x} \pm t_{\alpha/2} \frac{s}{\sqrt{n}}.$$

# Intervalos de confianza para $\sigma^2$

Supongamos que  $X$  se distribuye normal  $(\mu, \sigma^2)$ , desconocidas.

Sea  $X_1, X_2, \dots, X_n$  muestra aleatoria de tamaño  $n$ ,  $s^2$  la varianza muestral.

Se sabe que  $X^2 = \frac{(n-1)s^2}{\sigma^2}$  se distribuye  $\chi^2_{n-1}$  grados de libertad. Su intervalo de confianza es

$$\begin{aligned} P \left\{ \chi^2_{1-\frac{\alpha}{2}, n-1} \leq X^2 \leq \chi^2_{\frac{\alpha}{2}, n-1} \right\} &= 1 - \alpha \\ P \left\{ \chi^2_{1-\frac{\alpha}{2}, n-1} \leq \frac{(n-1)s^2}{\sigma^2} \leq \chi^2_{\frac{\alpha}{2}, n-1} \right\} &= 1 - \alpha \\ P \left\{ \frac{(n-1)s^2}{\chi^2_{\frac{\alpha}{2}, n-1}} \leq \sigma^2 \leq \frac{(n-1)s^2}{\chi^2_{1-\frac{\alpha}{2}, n-1}} \right\} &= 1 - \alpha \end{aligned} \tag{2}$$

es decir

# Intervalos de confianza para $\sigma^2$

$$\sigma^2 \in \left[ \frac{(n-1)s^2}{\chi_{\frac{\alpha}{2}, n-1}^2}, \frac{(n-1)s^2}{\chi_{1-\frac{\alpha}{2}, n-1}^2} \right] \quad (3)$$

los intervalos unilaterales son

$$\sigma^2 \in \left[ \frac{(n-1)s^2}{\chi_{\frac{\alpha}{2}, n-1}^2}, \infty \right) - \quad (4)$$

$$\sigma^2 \in \left( -\infty, \frac{(n-1)s^2}{\chi_{1-\frac{\alpha}{2}, n-1}^2} \right] \quad (5)$$

# Intervalos de confianza para proporciones

Supongamos que se tienen una muestra de tamaño  $n$  de una población grande pero finita, y supongamos que  $X, X \leq n$ , pertenecen a la clase de interés, entonces

$$\hat{p} = \frac{\bar{X}}{n}$$

es el estimador puntual de la proporción de la población que pertenece a dicha clase.

$n$  y  $p$  son los parámetros de la distribución binomial, entonces  $\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right)$  aproximadamente si  $p$  es distinto de 0 y 1; o si  $n$  es suficientemente grande. Entonces

$$Z = \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \sim N(0, 1), \text{ aproximadamente.}$$

# Intervalos de confianza para proporciones

entonces

$$\begin{aligned}1 - \alpha &= P \left\{ -z_{\alpha/2} \leq \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \leq z_{\alpha/2} \right\} \\&= P \left\{ \hat{p} - z_{\alpha/2} \sqrt{\frac{p(1-p)}{n}} \leq p \leq \hat{p} + z_{\alpha/2} \sqrt{\frac{p(1-p)}{n}} \right\}\end{aligned}$$

con  $\sqrt{\frac{p(1-p)}{n}}$  error estándar del estimador puntual  $p$ . Una solución para determinar el intervalo de confianza del parámetro  $p$  (desconocido) es

# Intervalos de confianza para proporciones

$$1 - \alpha = P \left\{ \hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \leq p \leq \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right\}$$

entonces los intervalos de confianza, tanto unilaterales como de dos colas son:

- ▶  $p \in \left( \hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right)$
- ▶  $p \in \left( -\infty, \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right)$
- ▶  $p \in \left( \hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \infty \right)$

para minimizar el error estándar, se propone que el tamaño de la muestra sea  $n = \left(\frac{z_{\alpha/2}}{E}\right)^2 p(1-p)$ , donde  $E = |p - \hat{p}|$ .

# Varianzas Conocidas

Sean  $X_1$  y  $X_2$  variables aleatorias independientes.  $X_1$  con media desconocida  $\mu_1$  y varianza conocida  $\sigma_1^2$ ; y  $X_2$  con media desconocida  $\mu_2$  y varianza conocida  $\sigma_2^2$ . Se busca encontrar un intervalo de confianza de  $100(1 - \alpha)\%$  de la diferencia entre medias  $\mu_1$  y  $\mu_2$ .

Sean  $X_{11}, X_{12}, \dots, X_{1n_1}$  muestra aleatoria de  $n_1$  observaciones de  $X_1$ , y sean  $X_{21}, X_{22}, \dots, X_{2n_2}$  muestra aleatoria de  $n_2$  observaciones de  $X_2$ .

Sean  $\bar{X}_1$  y  $\bar{X}_2$ , medias muestrales, entonces el estadístico

$$Z = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1), \quad (6)$$

si  $X_1$  y  $X_2$  son normales o aproximadamente normales si se aplican las condiciones del Teorema de Límite Central respectivamente.

# Varianzas conocidas

Entonces se tiene

$$\begin{aligned}1 - \alpha &= P\{-Z_{\alpha/2} \leq Z \leq Z_{\alpha/2}\} \\&= P\left\{-Z_{\alpha/2} \leq \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \leq Z_{\alpha/2}\right\} \\&= P\left\{(\bar{X}_1 - \bar{X}_2) - Z_{\alpha/2}\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \leq \mu_1 - \mu_2 \leq \right. \\&\quad \left. (\bar{X}_1 - \bar{X}_2) + Z_{\alpha/2}\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}\right\}\end{aligned}$$

# Varianzas conocidas

Entonces los intervalos de confianza unilaterales y de dos colas al  $(1 - \alpha)$  % de confianza son

- ▶  $\mu_1 - \mu_2 \in \left[ (\bar{X}_1 - \bar{X}_2) - Z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, (\bar{X}_1 - \bar{X}_2) + Z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right]$
- ▶  $\mu_1 - \mu_2 \in \left[ -\infty, (\bar{X}_1 - \bar{X}_2) + Z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right]$
- ▶  $\mu_1 - \mu_2 \in \left[ (\bar{X}_1 - \bar{X}_2) - Z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, \infty \right]$

# Varianzas conocidas

## Nota

*Si  $\sigma_1$  y  $\sigma_2$  son conocidas, o por lo menos se conoce una aproximación, y los tamaños de las muestras  $n_1$  y  $n_2$  son iguales,  $n_1 = n_2 = n$ , se puede determinar el tamaño de la muestra para que el error al estimar  $\mu_1 - \mu_2$  usando  $\bar{X}_1 - \bar{X}_2$  sea menor que  $E$  (valor del error deseado) al  $(1 - \alpha)$  % de confianza. El tamaño  $n$  de la muestra requerido para cada muestra es*

$$n = \left( \frac{Z_{\alpha/2}}{E} \right)^2 (\sigma_1^2 + \sigma_2^2).$$

# Varianzas desconocidas

- ▶ Si  $n_1, n_2 \geq 30$  se pueden utilizar los intervalos de la distribución normal para varianza conocida
- ▶ Si  $n_1, n_2$  son muestras pequeñas, supongase que las poblaciones para  $X_1$  y  $X_2$  son normales con varianzas desconocidas y con base en el intervalo de confianza para distribuciones  $t$ -student

$$\sigma_1^2 = \sigma_2^2 = \sigma$$

Supongamos que  $X_1$  es una variable aleatoria con media  $\mu_1$  y varianza  $\sigma_1^2$ ,  $X_2$  es una variable aleatoria con media  $\mu_2$  y varianza  $\sigma_2^2$ . Todos los parámetros son desconocidos. Sin embargo supóngase que es razonable considerar que  $\sigma_1^2 = \sigma_2^2 = \sigma^2$ .

Nuevamente sean  $X_1$  y  $X_2$  variables aleatorias independientes.  $X_1$  con media desconocida  $\mu_1$  y varianza muestral  $S_1^2$ ; y  $X_2$  con media desconocida  $\mu_2$  y varianza muestral  $S_2^2$ . Dado que  $S_1^2$  y  $S_2^2$  son estimadores de  $\sigma^2$ , se propone el estimador  $S$  de  $\sigma^2$  como

$$S_p^2 = \frac{(n_1 - 1) S_1^2 + (n_2 - 1) S_2^2}{n_1 + n_2 - 2},$$

entonces, el estadístico para  $\mu_1 - \mu_2$  es

$$\sigma_1^2 = \sigma_2^2 = \sigma$$

$$t_{\nu} = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

donde  $t_{\nu}$  es una  $t$  de student con  $\nu = n_1 + n_2 - 2$  grados de libertad.

Por lo tanto

$$\begin{aligned} 1 - \alpha &= P \left\{ -t_{\alpha/2, \nu} \leq t \leq t_{\alpha/2, \nu} \right\} \\ &= P \left\{ (\bar{X}_1 - \bar{X}_2) - t_{\alpha/2, \nu} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \leq \right. \\ &\quad \left. t \leq (\bar{X}_1 - \bar{X}_2) + t_{\alpha/2, \nu} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right\} \end{aligned}$$

$$\sigma_1^2 = \sigma_2^2 = \sigma$$

luego, los intervalos de confianza del  $(1 - \alpha)$  % para  $\mu_1 - \mu_2$  son

- ▶  $\mu_1 - \mu_2 \in \left[ (\bar{X}_1 - \bar{X}_2) - t_{\alpha/2,\nu} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}, (\bar{X}_1 - \bar{X}_2) + t_{\alpha/2,\nu} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right]$
- ▶  $\mu_1 - \mu_2 \in \left[ -\infty, (\bar{X}_1 - \bar{X}_2) + t_{\alpha/2,\nu} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right]$
- ▶  $\mu_1 - \mu_2 \in \left[ (\bar{X}_1 - \bar{X}_2) - t_{\alpha/2,\nu} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}, \infty \right]$

# Varianzas desconocidas

Si no se tiene certeza de que  $\sigma_1^2 = \sigma_2^2$ , se propone el estadístico

$$t^* = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} \quad (7)$$

que se distribuye  $t$ -student con  $\nu$  grados de libertad, donde

$$\nu = \frac{\left( \frac{s_1^2}{n_1} + \frac{s_2^2}{n_2} \right)^2}{\frac{s_1^2/n_1}{n_1+1} + \frac{s_2^2/n_2}{n_2+1}} - 2$$

# Varianzas desconocidas

Entonces el intervalo de confianza de aproximadamente el  $100(1 - \alpha)\%$  para  $\mu_1 - \mu_2$  con  $\sigma_1^2 \neq \sigma_2^2$  es

$$\begin{aligned}\mu_1 - \mu_2 &\in \left[ (\bar{X}_1 - \bar{X}_2) - t_{\alpha/2, \nu} \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}, \right. \\ &\quad \left. (\bar{X}_1 - \bar{X}_2) + t_{\alpha/2, \nu} \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}} \right]\end{aligned}$$

# Distribuciones Pareadas

Supongamos que se toman dos muestras aleatorias independientes de las dos poblaciones de interés

```
> a <- -2;  
> b <- 2;  
> N <- 10000;  
> t <- runif(N, min =a, max=b)  
> hist(t,freq = FALSE,  
+       col = "blue",  
+       xlab = 'Graficando uniformes [-1,1]',  
+       density = 30,  
+       main = "DISTRIBUCION UNIFORME EN EL INTERVALO  
> curve(dunif(x, min = a, max = b),  
+         from = -5, to = 5,  
+         n = N,  
+         col = "darkblue",  
+         lwd = 2,  
+         add = TRUE,  
+         yaxt = "n",  
+         ylab = 'probability')  
> #-----
```

```
> # utilizando la libreria ggplot2
> #-----
> library(ggplot2)
> #-----
> xvals <- data.frame(x = c(a, b)) #Range for x-values
> ggplot(data.frame(x = xvals), aes(x = x)) +
+   xlim(c(a, b)) +
+   ylim(c(0, 1/4)) +
+   stat_function(fun = dunif,
+                 args = list(min = a, max = b),
+                 geom = "area",
+                 fill = "green",
+                 alpha = 0.35) +
+   labs(x = "\n u",
+        y = "f(u) \n",
+        title = "Uniform Distribution With a = -2 and b = 2",
+        theme(plot.title = element_text(hjust = 0.5),
+              axis.title.x = element_text(face="bold",
```

```
+                               colour="blue",
+
+           axis.title.y = element_text(face="bold",
+                                         colour="blue",
+                                         size = 12)) +
+
+   geom_vline(xintercept = a,
+              linetype = "dashed",
+              colour = "red") +
+
+   geom_vline(xintercept = b,
+              linetype = "dashed",
+              colour = "red")
> #-----
> # ggplot Histogram
> # Uniform Distribution With a = -2 and b = 2
> #-----
> unifs <- runif(n = 10000, min = a, max = b)
> ggplot(data = NULL, aes(x = unifs)) +
+   geom_histogram(binwidth = 0.25, boundary = 2)
```

```
+   xlim(c(-3, 3)) +
+   ylim(c(-10, 800)) +
+   labs(x = "\n u",
+        y = "f(u) \n",
+        title = "Uniform Distribution With a = -2 and b = 1",
+        theme(plot.title = element_text(hjust = 0.5),
+              axis.title.x = element_text(face="bold",
+                                           colour="brown",
+                                           size = 12),
+              axis.title.y = element_text(face="bold",
+                                           colour="brown",
+                                           size = 12))
+
> #-----#
> # Standard Uniform Distribution With a = 0 and b = 1
> #-----#
> a=0;
> b=1;
> std_unifs <- runif(n = N, min = a, max = b)
```

```
> #-----  
> # ggplot Histogram  
> #-----  
> ggplot(data = NULL, aes(x = std_unifs)) +  
+   geom_histogram(binwidth = 0.05, boundary = 1) +  
+   xlim(c(-0.05, 1.05)) +  
+   labs(x = "\n u", y = "f(u) \n",  
+         title = "Uniform Distribution With a = 0 and  
+ theme(plot.title = element_text(hjust = 0.5),  
+       axis.title.x = element_text(face="bold",  
+                                     colour="brown",  
+                                     size = 12),  
+       axis.title.y = element_text(face="bold",  
+                                     colour="brown",  
+                                     size = 12))  
> #-----  
> # otra alternativa  
> #-----
```

```

> t <- runif(N)*10; head(t)
[1] 0.3427805 0.6261653 5.7132067 0.9506013 1.7658213 7

> tf<- floor(t);head(t)

[1] 0.3427805 0.6261653 5.7132067 0.9506013 1.7658213 7

> table(tf)


tf
 0   1   2   3   4   5   6   7   8   9 
980 1014 1018 964 1003 1020 937 1031 1029 1004

> barplot(table(tf),
+           xlab="NUMEROS GENERADOS",
+           ylab="NUMERO DE OCURRENCIAS",
+           border="red",
+           main = "Ejemplo de generacion de Variables Aleatorias")
> #-----#
> # EJERCICIO 1) GENERAR UNA FUNCION QUE GRAFIQUE UNA DISTRIBUCION DE PROBABILIDADES DE LA CIUDAD DE MEXICO
> # VARIANDO EL NUMERO DE V.A. GENERADAS
```

> # EJERCICIO 2) MEJORAR LOS GRAFICOS

> #-----

## DISTRIBUCION UNIFORME EN EL INTERVALO [-1,1]



```
> #setwd("~/Nextcloud/TodoMundoFiles/Curso Estadistica")
> #
> # -----
> # PARA UNA DISTRIBUCION NORMAL ESTANDAR
> #
> # -----
> # Para determinar los valores de  $Z_{\alpha/2}$ 
> # Ejecutar los siguientes comandos
> #
> # -----
> z <- qnorm(0.05); print(z)
[1] -1.644854
> z <- qnorm(0.01); print(z)
[1] -2.326348
> z <- qnorm(0.025); print(z)
[1] -1.959964
> z <- qnorm(0.1); print(z)
[1] -1.281552
```

```
> z <- qnorm(0.001); print(z)
[1] -3.090232

> # _____
> # Para una distribucion Normal(mu,sigma2), los cuartiles
> # Q1 <- 0.25
> # Q2 <- 0.5
> # Q3 <- 0.75
> # la funcion a utilizar es: qnorm(p, mean= mu, sd =
> # _____
> mu      <- 2;
> sigma2 <- 4;
> q1      <- 0.25; Q1 <- qnorm(q1,mean=mu,sd = sigma2);
[1] -0.697959

> q2      <- 0.5; Q2 <- qnorm(q2,mean=mu,sd = sigma2);
[1] 2

> q3      <- 0.75; Q3 <- qnorm(q3,mean=mu,sd = sigma2);
```

```
[1] 4.697959
```


```
> # -----  
> # Comparemos los resultados anteriores con las salidas  
> # comando p(norm)  
> z <- pnorm(1.64); print(z)  
[1] 0.9494974  
  
> z <- pnorm(2.32); print(z)  
[1] 0.9898296  
  
> z <- pnorm(1.96); print(z)  
[1] 0.9750021  
  
> z <- pnorm(1.28); print(z)  
[1] 0.8997274  
  
> # -----  
> # -----  
> # Ahora proporcionemos una bonita grafica de una distribucion normal.
```

```
> # -----
> N      <- 10000
> mu     <- 10
> sigma2 <- 2
> x      <- rnorm(N,mean=mu, sd=sigma2)
> hist(x,
+       breaks=150,
+       xlim=c(0,20),
+       freq=FALSE,
+       col = "blue",
+       xlab = 'N(mu,sigma2)',
+       density = 30,
+       main = "Graficando una VA Normal con mu = 10 y
> abline(v=mu, lwd=5)
> abline(v=c(4,6,8,12,14,16), lwd=3,lty=3)
> #
> #
> #
```

> #

---


## Graficando una VA Normal con mu = 10 y Var=2




```
> set.seed(3000)
> xseq           <- seq(-4,4,.01)
> densities      <- dnorm(xseq, 0,1)
> cumulative     <- pnorm(xseq, 0, 1)
> randomdeviates <- rnorm(1000,0,1)
> par(mfrow=c(3,1))
> #par(mfrow=c(1,3), mar=c(3,4,4,2))
> plot(xseq,
+       densities,
+       col="darkgreen",
+       xlab="",
+       ylab="Densidad",
+       type="l",
+       lwd=2,
+       cex=2,
+       main="PDF de una Distribucion Normal Estandar",
+       cex.axis=.8)
> plot(xseq,
```

```
+      cumulative,
+      col="darkorange",
+      xlab="",
+      ylab="Funcion de Probabilidad Acumulada",
+      type="l",
+      lwd=2,
+      cex=2,
+      main="CDF de una Distribucion Normal Estandar"
+      cex.axis=.8)
> x<- rnorm(1000,0,1)
> hist(x,
+       main="Simulacion de una VA Normal(0,1)",
+       ylab= 'Frecuencia',
+       xlab='Histograma de una VA Normal(0,1)',
+       cex.axis=.8,
+       xlim=c(-4,4))
```


### PDF de una Distribucion Normal Estandar



### CDF de una Distribucion Normal Estandar



### Simulacion de una VA Normal(0,1)




## Ahora veamos un ejemplo más práctico

```
> mu           <- 69;  
> sigma2       <- 2.8;  
> DE_rellenar <- 1;  
> LI <- mu-sigma2*DE_rellenar  
> LS <- mu+sigma2*DE_rellenar  
> #Se generan valores equiespaciados entre -4 y 4 des  
> #alrededor de la media  
> x <- seq(-4, 4, length = 1000) * sigma2 + mu  
> y <- dnorm(x, mu, sigma2)  
> plot(x, y,  
+       type="n",  
+       xlab = "Longitud (inches)",  
+       ylab = "",  
+       main = "Distribucion de las alturas de hombres  
+       axes = FALSE)  
> lines(x, y)  
> bounds_filter <- x >= LI & x <= LS
```

```
> x_within_bounds <- x[bounds_filter]
> y_within_bounds <- y[bounds_filter]
> x_polygon <- c(LI, x_within_bounds, LS)
> y_polygon <- c(0, y_within_bounds, 0)
> polygon(x_polygon, y_polygon, col = "red")
> probability_within_bounds <- pnorm(LS, mu, sigma2) -
> text <- paste("p(", LI, "< height <", LS, ") =", sigma2)
> mtext(text)
> sd_axis_bounds = 5
> axis_bounds <- seq(-sd_axis_bounds * sigma2 + mu, sd_axis_bounds * sigma2 + mu, length.out = 5)
> axis(side = 1, at = axis_bounds, pos = 0)
```

## Distribucion de las alturas de hombres





$$p( 66.2 < \text{height} < 71.8 ) = 0.683$$





Otras instrucciones que realizan algo semejante a lo hasta ahora mostrado son las siguientes:

```
> # Parametros iniciales  
> par(mfrow=c(2,2))  
> a      <- -4;  
> b      <- 4;  
> N      <- 200;  
> DE     <- 1;  
> mu     <- 0;  
> sigma2 <- 1;  
> # Comencemos a graficar  
> x=seq(a,b,length=N)  
> y=1/sqrt(2*pi)*exp(-x^2/2)  
> # Primer Grafica  
> plot(x,y,type="l",lwd=2,col="red")  
> # Segunda Grafica  
> x=seq(a,b,length=N)  
> y=dnorm(x,mean=mu,sd=sigma2)
```

```
> plot(x,y,type="l",lwd=2,col="red")
> # Tercer Grafica
> x=seq(a,b,length=N)
> y=dnorm(x)
> plot(x,y,type="l", lwd=2, col="blue")
> x=seq(a,DE,length=N)
> y=dnorm(x)
> polygon(c(a,x,DE),c(0,y,0),col="gray")
> #Cuarta grafica
> x=seq(a,b,length=N)
> y=dnorm(x)
> plot(x,y,type="l", lwd=2, col="blue")
> x=seq(-DE,DE,length=100)
> y=dnorm(x)
> polygon(c(-DE,x,DE),c(0,y,0),col="gray")
```




```
> # Primera grafica
> par(mfrow=c(2,1))
> x=seq(a,b,length=N)
> y=dnorm(x)
> plot(x,y,type="l", lwd=2, col="blue")
> x=seq(-2*DE,2*DE,length=N)
> y=dnorm(x)
> polygon(c(-2*DE,x,2*DE),c(0,y,0),col="gray")
> # Segunda grafica
> x=seq(a,b,length=N)
> y=dnorm(x)
> plot(x,y,type="l",lwd=2,col="blue")
> x=seq(-3*DE,3*DE,length=N)
> y=dnorm(x)
> polygon(c(-3*DE,x,3*DE),c(0,y,0),col="gray")
```




```
> stdnormsamp <- rnorm(100,mean=0,sd=1)
> normsamp <- rnorm(100,mean=5,sd=1)
> binomsamp <- rbinom(100,size=20,prob=.25)
> poissamp <- rpois(100,5)
> par(mfrow=c(2,2))
> qqnorm(stdnormsamp,main="Normal Q-Q plot : N(0,1) sample")
> qqline(stdnormsamp,col=2)
> qqnorm(normsamp,main="Normal Q-Q plot : N(5,1) sample")
> qqline(normsamp,col=2)
> qqnorm(binomsamp,main="Normal Q-Q plot : Bin(20,.25) sample")
> qqline(binomsamp,col=2)
> qqnorm(poissamp,main="Normal Q-Q plot : Poisson(5) sample")
> qqline(poissamp,col=2)
```


**Normal Q-Q plot :  $N(0,1)$  samples**




**Normal Q-Q plot :  $N(5,1)$  samples**



**Normal Q-Q plot :  $\text{Bin}(20,.25)$  samples**




**Normal Q-Q plot : Poisson(5) samples**




```
> par(mfrow=c(2,1))
> qqplot(stdnormsamp,
+         normsamp,
+         xlab = "Sample quantiles :  $N(0,1)$  samples",
+         ylab = "Sample quantiles :  $N(5,1)$  samples")
> qqplot(stdnormsamp,
+         binomsamp,
+         xlab = "Sample quantiles :  $N(0,1)$  samples",
+         ylab = "Sample quantiles : Bin(20,.25) sample")
```

Sample quantiles :  $N(5,1)$  samples



Sample quantiles :  $N(0,1)$  samples

Sample quantiles :  $Bin(20, .25)$  samples



-  Normal Distribution Functions, *R-bloggers*, <https://www.r-bloggers.com/normal-distribution-functions/>
-  Plotting a Normal Distribution with R, *Matt Mazur Home Page*, <https://mattmazur.com/2014/10/25/plotting-a-normal-distribution-with-r/>
-  Normal Distribution, *R Tutorial: An Introduction to Statistics*, <http://www.r-tutor.com/elementary-statistics/probability-distributions/normal-distribution>
-  The Standard Normal Distribution in R, *Department of Mathematics, College of the Redwoods*, <http://msenux2.redwoods.edu/MathDept/R/StandardNormalDistribution.html>
-  Michael Minn Home Page, *The Normal Distribution in R*, <http://michaelminn.net/tutorials/r-normal-rank-order/>