Predicción de sitios alostéricos mediante técnicas de aprendizaje supervisado y análisis estructural

Carlos E Martínez-Rodríguez

Índice

1. Forensic Data Science **1**
1.1. ¿Qué es Forensic Data Science? . . . 1
1.2. Tipos de evidencia donde se aplica . . . 1
1.3. Forensic Statistics: base matemática . . . 1
1.4. Machine Learning en investigación criminal . . . 2
1.5. Problemas científicos abiertos . . . 2
1.6. Centros de investigación importantes . . . 2
1.7. Libros clave del área . . . 2
1.8. Pipeline típico de Forensic Data Science . . . 2
1.9. Posibles aplicaciones . . . 3

2. Datasets Públicos para Investigación en Forensic Data Science **3**
2.1. Datos de Criminalidad . . . 3
2.2. Datasets de Evidencia Digital . . . 3
2.3. Datasets Biométricos . . . 3
2.4. Datasets para Detección de Fraude . . . 3
2.5. Importancia de los Datasets Públicos . . . 3

3. Papers Fundacionales en Forensic Data Science **3**
3.1. Fundamentos de Estadística Forense . . . 3
3.2. Evaluación Probabilística de Evidencia . . . 4
3.3. Machine Learning en Ciencias Forenses . . . 4
3.4. Importancia de la Interpretabilidad . . . 4
3.5. Referencias Clave . . . 4

4. Pipeline Metodológico en Forensic Data Science **4**
4.1. Contexto general y principios . . . 4
4.2. Pipeline completo . . . 4
4.3. Ejemplo guiado: Clasificación forense con PCA + Regresión Logística . . . 5

5. Modelado Bayesiano en Forensic Data Science y Simulación de Datos Sintéticos **6**
5.1. Marco bayesiano básico: hipótesis y evidencia . . . 6
5.2. Modelo sintético 1: Evidencia univariada (caso didáctico) . . . 7
5.3. Modelo . . . 7
5.4. Simulación sintética . . . 7
5.5. Modelo sintético 2: Evidencia multivariada (más realista) . . . 7
5.6. Modelo generativo gaussiano . . . 7
5.7. Modelo sintético 3: Población (Defense) como mezcla . . . 7
5.8. Prior conjugado (Normal-Inversa-Wishart) . . . 7

6. Protocolo de simulación sintética (recomendado) **8**
6.1. Diseño experimental . . . 8

7. Investigación en Ciencia Forense y Estadística en México **8**
7.1. Universidad Nacional Autónoma de México (UNAM) . . . 8
7.2. Equipo Mexicano de Antropología Forense (EMAF) . . . 8
7.3. Instituto Nacional de Ciencias Penales . . . 8
7.4. Investigación cuantitativa sobre crimen en México . . . 8
7.5. Análisis de redes criminales . . . 8
7.6. Crisis forense en México y necesidad de métodos cuantitativos . . . 9
7.7. Oportunidad científica . . . 9

7.8. Investigación y Datos Abiertos para Forensic Data Science en México . . . 9
7.9. Investigadores e instituciones cercanas al área . . . 9
7.10. Centro de Investigación y Docencia Económicas (CIDE) . . . 9

8. Bases de datos abiertas en México **9**
8.1. Datos Abiertos del Gobierno de México . . . 9
8.2. Secretariado Ejecutivo del Sistema Nacional de Seguridad Pública . . . 9
8.3. INEGI . . . 9

9. Áreas de oportunidad **9**
9.1. Propuesta de Investigación: Bayesian Forensic Data Science en México . . . 10
9.2. Datos . . . 10
9.3. Metodología . . . 10
9.4. Resultados esperados . . . 11
9.5. Impacto . . . 11
9.6. Diseño del experimento . . . 11

10. Roles posibles para un especialista en estadística forense **14**
10.1. Perito estadístico . . . 14
10.2. Consultor en análisis de datos criminales . . . 15
10.3. Asesor en laboratorios forenses . . . 15
10.4. Desarrollo de software analítico . . . 15

11. Principales investigadores **15**

12. Centros de investigación importantes **15**

13. Plan de trabajo **16**
13.1. Fase I: Fundamentos metodológicos (Año 1) . . . 16
13.2. Fase II: Aplicación a problemas criminales (Años 2–3) . . . 16
13.3. Fase III: Colaboración institucional (Años 3–4) . . . 16
13.4. Fase IV: Consolidación y transferencia (Años 4–5) . . . 16
13.5. Impacto académico y profesional . . . 16

1. Forensic Data Science

El área de *Forensic Data Science* es particularmente interesante porque se encuentra en la intersección de varias disciplinas científicas, entre ellas la estadística, el *machine learning*, la criminología y la ciencia forense. En los últimos años este campo ha emergido como una disciplina formal cuyo objetivo es mejorar la interpretación cuantitativa de la evidencia y reducir errores dentro de los sistemas judiciales.

1.1. ¿Qué es Forensic Data Science?

Forensic Data Science se refiere al uso de métodos cuantitativos, estadísticos y computacionales para: analizar evidencia forense, evaluar hipótesis legales, modelar incertidumbre en evidencia, detectar patrones criminales. Este campo integra diversas áreas del conocimiento, entre ellas: estadística bayesiana, *machine learning*, minería de datos, análisis de redes, visión computacional, análisis espacial.

1.2. Tipos de evidencia donde se aplica

ADN y genética forense

La genética forense constituye una de las áreas más avanzadas en ciencia de datos aplicada al ámbito forense. Entre los problemas típicos que se abordan se encuentran: análisis de mezclas de ADN (muestras con múltiples individuos), estimación de probabilidades de coincidencia genética, identificación de individuos. Para abordar estos problemas se utilizan métodos como: inferencia bayesiana, modelos probabilísticos, algoritmos de tipo *Markov Chain Monte Carlo* (MCMC). Entre las herramientas más conocidas se encuentran: *TrueAllele*, *STRmix*.

Huellas digitales

La identificación de huellas digitales utiliza técnicas provenientes de: *computer vision*, *pattern recognition*. Las variables estructurales más relevantes en el análisis de huellas incluyen: minucias, bifurcaciones, terminaciones de crestas. Entre los algoritmos utilizados se encuentran: *Support Vector Machines* (SVM), redes neuronales, *deep learning*, métodos de *matching* probabilístico.

Evidencia digital

En el ámbito de la evidencia digital, la ciencia de datos se utiliza para analizar: discos duros, teléfonos móviles, redes sociales, registros de sistemas (*logs*). Entre las aplicaciones más comunes se encuentran: detección de fraude, reconstrucción de eventos, análisis de comunicaciones. Las técnicas utilizadas incluyen: procesamiento de lenguaje natural (*NLP*), análisis de grafos, *clustering*, detección de anomalías.

1.3. Forensic Statistics: base matemática

Una parte fundamental de *Forensic Data Science* se basa en la estadística bayesiana. El concepto central en la evaluación probabilística de evidencia es la *Likelihood Ratio* (LR):

$$LR = \frac{P(E \mid H_p)}{P(E \mid H_d)} \tag{1}$$

donde: E representa la evidencia observada, H_p corresponde a la hipótesis de la fiscalía, H_d corresponde a la hipótesis de la defensa. La interpretación de la razón de verosimilitud es la siguiente:

LR	Interpretación
1	evidencia neutra
> 1	favorece la hipótesis de la fiscalía
< 1	favorece la hipótesis de la defensa

Este enfoque se utiliza ampliamente en áreas como: análisis de ADN, balística, análisis de voz, identificación mediante huellas digitales.

1.4. Machine Learning en investigación criminal

La ciencia de datos también se emplea para analizar patrones criminales.

Predicción del crimen

Para la predicción de eventos criminales se utilizan datos como: ubicación geográfica, horario del incidente, tipo de crimen, variables socioeconómicas. Entre los modelos utilizados se encuentran: *Random Forest*, *Gradient Boosting*, modelos espaciales, redes neuronales.

Análisis de redes criminales

En el análisis de redes criminales se modelan relaciones entre individuos involucrados en actividades ilícitas.

Las herramientas utilizadas incluyen: teoría de grafos, medidas de centralidad en redes, detección de comunidades (*community detection*). Estas técnicas se aplican al estudio de: carteles criminales, redes de fraude, organizaciones terroristas.

1.5. Problemas científicos abiertos

El campo de *Forensic Data Science* aún presenta varios problemas científicos activos.

1. **Interpretación de evidencia**: ¿Cómo cuantificar evidencia de forma objetiva y reproducible?
2. **Sesgo en sistemas forenses**: Muchos métodos tradicionales, como la identificación por huellas o balística, han sido criticados por la falta de bases estadísticas sólidas.
3. **Explicabilidad de modelos de aprendizaje automático**: Los sistemas utilizados en contextos judiciales deben ser interpretables para poder ser presentados ante tribunales.
4. **Integración de múltiples evidencias**: En muchos casos es necesario combinar diferentes tipos de evidencia, como: ADN, huellas, video, datos digitales.

1.6. Centros de investigación importantes

Entre los centros de investigación más relevantes en el desarrollo de estadística forense se encuentran: *Netherlands Forensic Institute*, *National Institute of Standards and Technology* (grupo de *forensic statistics*), *University of Lausanne School of Criminal Justice*.

1.7. Libros clave del área

Estadística forense

Entre los textos más influyentes se encuentran: *Forensic Statistics: An Introduction to Bayesian Methods*, *Statistics and the Evaluation of Evidence for Forensic Scientists*. Autores importantes en este campo incluyen: Colin Aitken, Franco Taroni.

Ciencia de datos forense

Un libro relevante en el área de análisis de fraude es: *Forensic Data Analytics*, de Mark Nigrini. Este texto es ampliamente utilizado en estudios de detección de fraude financiero.

1.8. Pipeline típico de Forensic Data Science

Un flujo de trabajo típico en *Forensic Data Science* incluye las siguientes etapas:

1. Recolección de evidencia: ADN, huellas, registros digitales.
2. Preprocesamiento: limpieza de datos, normalización, extracción de características
3. Modelado: estadística bayesiana, modelos de *machine learning*
4. Evaluación probabilística: cálculo de *likelihood ratios*, intervalos de confianza
5. Reporte para tribunal: interpretación clara, visualización de resultados

1.9. Posibles aplicaciones

Las herramientas desarrolladas en *Forensic Data Science* pueden aplicarse a problemas como: clasificación automática de huellas digitales, análisis de mezclas de ADN, detección de fraude financiero, análisis de redes criminales. El desarrollo de métodos estadísticos y computacionales para estos problemas representa una línea de investigación activa con aplicaciones tanto científicas como institucionales.

2. Datasets Públicos para Investigación en Forensic Data Science

El desarrollo de métodos de *Forensic Data Science* requiere conjuntos de datos que permitan evaluar algoritmos estadísticos y de *machine learning* aplicados al análisis de evidencia. Existen varios datasets públicos utilizados en investigación académica y desarrollo metodológico en áreas como criminología, evidencia digital, biometría y detección de fraude.

2.1. Datos de Criminalidad

Uno de los conjuntos de datos más utilizados en investigación criminológica es el conjunto de datos de criminalidad del *Federal Bureau of Investigation* (FBI), obtenido a través del programa *Uniform Crime Reporting* (UCR). Estos datos incluyen información sobre: Tipo de crimen, Ubicación geográfica, Fecha y hora del incidente, Características demográficas. Este tipo de información permite desarrollar modelos para: predicción de *crime hotspots*, análisis espacial del crimen, modelado de patrones criminales. Otro dataset importante proviene de la ciudad de Chicago, disponible públicamente y ampliamente utilizado en investigación en ciencia de datos aplicada a criminología.

2.2. Datasets de Evidencia Digital

En el área de *digital forensics* existen datasets diseñados específicamente para estudiar técnicas de análisis de evidencia digital. Un ejemplo importante es el conjunto de datos desarrollado por el *Digital Corpora Project*, que contiene: imágenes completas de discos duros, registros de actividad digital, datos de sistemas operativos. Estos datasets permiten investigar problemas como: recuperación de información eliminada, reconstrucción de eventos digitales, detección de actividad maliciosa.

2.3. Datasets Biométricos

En el ámbito de identificación biométrica existen varios datasets utilizados para investigación en reconocimiento de patrones. Entre ellos se encuentran: bases de datos de huellas digitales, bases de datos de reconocimiento facial, conjuntos de datos de reconocimiento de voz. Estos datasets permiten evaluar algoritmos de: clasificación, reconocimiento de patrones, aprendizaje profundo aplicado a biometría.

2.4. Datasets para Detección de Fraude

Otra área importante dentro de la ciencia de datos forense es la detección de fraude financiero. Existen datasets públicos que contienen: transacciones financieras, patrones de gasto, registros de actividad bancaria. Estos conjuntos de datos se utilizan para entrenar modelos de: detección de anomalías, clasificación supervisada, aprendizaje no supervisado.

2.5. Importancia de los Datasets Públicos

El acceso a datasets públicos es fundamental para el desarrollo de métodos reproducibles en ciencia de datos forense. Permiten: comparar algoritmos de análisis, validar métodos estadísticos, desarrollar nuevas herramientas computacionales para análisis de evidencia. Además, facilitan la formación de investigadores en el campo de la ciencia de datos aplicada al análisis forense.

3. Papers Fundacionales en Forensic Data Science

El campo de *Forensic Data Science* se ha desarrollado principalmente a partir de avances en estadística forense, inferencia bayesiana y métodos computacionales aplicados al análisis de evidencia. Diversos trabajos académicos han sido fundamentales para establecer los principios metodológicos que hoy se utilizan en la interpretación cuantitativa de evidencia forense.

3.1. Fundamentos de Estadística Forense

Uno de los trabajos más influyentes en el desarrollo de la estadística forense moderna es el realizado por Aitken y Taroni, quienes propusieron el uso sistemático de métodos bayesianos para evaluar evidencia científica en contextos judiciales. En este enfoque, la evidencia se evalúa mediante el cálculo de la razón de verosimilitud (*Likelihood Ratio*), definida como:

$$LR = \frac{P(E \mid H_p)}{P(E \mid H_d)} \tag{2}$$

donde: E representa la evidencia observada, H_p corresponde a la hipótesis de la fiscalía, H_d corresponde a la hipótesis de la defensa. Este marco probabilístico permite cuantificar el peso de la evidencia de manera objetiva y transparente, evitando interpretaciones subjetivas.

3.2. Evaluación Probabilística de Evidencia

Otro trabajo fundamental es el artículo de Taroni, Aitken, Garbolino y Biedermann, donde se desarrolla un marco formal para la evaluación probabilística de evidencia forense utilizando redes bayesianas. Las redes bayesianas permiten modelar relaciones probabilísticas entre múltiples variables asociadas con la evidencia, lo cual es particularmente útil en casos donde existen múltiples fuentes de incertidumbre. Entre las aplicaciones principales se encuentran: análisis de ADN, evaluación de huellas digitales, análisis de evidencia balística, interpretación de evidencia digital.

3.3. Machine Learning en Ciencias Forenses

En años recientes, diversos trabajos han explorado el uso de técnicas de *machine learning* para automatizar procesos de identificación y clasificación en evidencia forense. Entre las aplicaciones más relevantes se encuentran: reconocimiento automático de huellas digitales, identificación facial, análisis de patrones criminales, detección de fraude financiero. Los algoritmos más utilizados incluyen: máquinas de soporte vectorial (SVM), *random forests*, redes neuronales profundas, métodos de aprendizaje no supervisado. Estos enfoques han permitido mejorar la precisión y reproducibilidad de los métodos tradicionales utilizados en laboratorios forenses.

3.4. Importancia de la Interpretabilidad

Un aspecto crucial en el uso de modelos de aprendizaje automático en ciencia forense es la interpretabilidad de los resultados. A diferencia de otras aplicaciones de ciencia de datos, en el contexto judicial es fundamental que los métodos utilizados puedan ser explicados de manera clara ante un tribunal. Por esta razón, muchos investigadores enfatizan el uso de modelos probabilísticos interpretables y técnicas estadísticas robustas.

3.5. Referencias Clave

Algunos trabajos influyentes en el desarrollo del campo incluyen:

- Aitken, C. G. G. y Taroni, F. (2004). *Statistics and the Evaluation of Evidence for Forensic Scientists.*
- Taroni, F., Aitken, C., Garbolino, P., y Biedermann, A. (2006). *Bayesian Networks and Probabilistic Inference in Forensic Science.*
- Nigrini, M. (2011). *Forensic Analytics.*

Estos trabajos han establecido las bases conceptuales para la aplicación de métodos cuantitativos y computacionales en el análisis de evidencia forense.

4. Pipeline Metodológico en Forensic Data Science

En este paso se propone un *pipeline* general, reproducible y defendible ante auditoría (y, en su caso, ante un tribunal), para desarrollar modelos de *Forensic Data Science*. El objetivo es pasar de evidencia cruda a un informe cuantitativo con incertidumbre explícita.

4.1. Contexto general y principios

En ciencia forense, un modelo no solo debe **predecir** o **clasificar**, sino también: justificar sus supuestos, cuantificar incertidumbre, ser replicable (misma evidencia $\Rightarrow$ mismo resultado bajo el mismo protocolo), ser interpretable o, al menos, explicable (especialmente si se usa *machine learning*).

4.2. Pipeline completo

Sea un conjunto de datos $D = \{(x_i, y_i)\}_{i=1}^n$, donde $x_i \in \mathbb{R}^p$ representa características extraídas de evidencia (señal, imagen, texto, metadatos) y y_i es una etiqueta (p. ej. clase, fuente, o hipótesis).

1. **Definición del problema forense:** Delimitar: *(i)* qué evidencia E se observa, *(ii)* qué hipótesis se comparan, y *(iii)* qué salida necesita el usuario final (perito, fiscalía, defensa).
2. **Adquisición y trazabilidad de datos**
   Registrar procedencia, controles, sesgos potenciales, y versiones de preprocesamiento.
3. **Preprocesamiento:** limpieza (valores faltantes, duplicados, inconsistencias), normalización/estandarización, control de *leakage* (no usar información futura o de etiqueta en etapas previas), partición entrenamiento/validación/-prueba (idealmente por caso o por sujeto).
4. **Extracción de características:** Ejemplos: *minucias* en huellas, MFCC en voz, *embeddings* en texto, descriptores en imagen, estadísticos de secuencia en logs digitales.
5. **Modelado:** Dos rutas frecuentes: **(A) Enfoque probabilístico** (recomendado en forense): razón de verosimilitud, modelos bayesianos, redes bayesianas. **(B) Enfoque predictivo/ML**: clasificación, detección de anomalías, *clustering*, modelos espaciales.
6. **Evaluación:** Métricas estándar (accuracy, F1, ROC-AUC) **y** métricas forenses: calibración (probabilidades bien calibradas), tasas de error por subpoblación, estabilidad a ruido/perturbaciones, sensibilidad a sesgo del muestreo.
7. **Interpretabilidad y reporte:** Incluir: variables más influyentes (p. ej. coeficientes, importancia, SHAP si aplica), intervalos de confianza / credibilidad, análisis de limitaciones, conclusión cuantitativa alineada al objetivo.

4.3. Ejemplo guiado: Clasificación forense con PCA + Regresión Logística

Escenario

Supongamos un laboratorio con mediciones instrumentales (p. ej. espectros, señales, o vectores de rasgos) de evidencia. Se busca discriminar entre dos clases:

$$y \in \{0, 1\},$$

por ejemplo:

- $y = 1$: evidencia compatible con una fuente S_1 (hipótesis H_p),
- $y = 0$: evidencia compatible con fuente alternativa S_0 (hipótesis H_d).

Estandarización

Sea $X \in \mathbb{R}^{n \times p}$ la matriz de características. Se estandariza columna a columna:

$$Z_{ij} = \frac{X_{ij} - \mu_j}{\sigma_j},$$

donde μ_j y σ_j son la media y desviación estándar de la característica j en el conjunto de entrenamiento.

Reducción de dimensión con PCA

PCA busca componentes principales:

$$T = ZW,$$

donde $W \in \mathbb{R}^{p \times k}$ contiene los primeros k autovectores de la matriz de covarianza (o correlación) de Z, y $T \in \mathbb{R}^{n \times k}$ son las coordenadas en el espacio reducido. Criterios comunes para elegir k: varianza explicada acumulada ($\geq 90\,\%$ o $\geq 95\,\%$), validación cruzada en el desempeño del clasificador.

Clasificador: Regresión logística

Se ajusta un modelo:

$$P(y = 1 \mid t) = \pi(t) = \frac{1}{1 + \exp\left(-(\beta_0 + \beta^\top t)\right)},$$

donde $t \in \mathbb{R}^k$ es el vector PCA del caso. Regla de decisión con umbral τ:

$$\hat{y} = \begin{cases} 1 & \text{si } \pi(t) \geq \tau, \\ 0 & \text{si } \pi(t) < \tau. \end{cases}$$

Conexión forense: salida tipo Likelihood Ratio (LR)

En un marco forense es deseable un *peso de evidencia*. Una forma (simplificada) es convertir una probabilidad calibrada a una razón de probabilidades (*odds*):

$$\text{odds}(t) = \frac{\pi(t)}{1 - \pi(t)}.$$

Si se dispone de una calibración adecuada para interpretar esto como soporte relativo entre hipótesis, se puede reportar:

$$LR(t) \approx \frac{\pi(t)}{1 - \pi(t)}.$$

Nota: en entornos periciales formales, el LR suele derivarse de modelos generativos (p. ej. densidades bajo H_p y H_d). Esta aproximación es útil como puente conceptual cuando se trabaja con clasificadores discriminativos, pero debe justificarse y validarse cuidadosamente.

Evaluación recomendada

- **Validación cruzada estratificada** (p. ej. $K = 5$ o 10).
- **Matriz de confusión** y métricas: sensibilidad, especificidad, F1.
- **ROC-AUC** para explorar umbrales τ.
- **Calibración** (curva de calibración y *Brier score*).

Reporte (plantilla breve)

- Descripción de evidencia y condiciones de adquisición.
- Preprocesamiento aplicado (incluyendo parámetros).
- Número de componentes PCA k y varianza explicada.
- Modelo final (tipo, hiperparámetros).
- Desempeño en prueba independiente o CV (con intervalos).
- Limitaciones y supuestos.
- Conclusión cuantitativa (probabilidad o LR, según corresponda) y su interpretación.

5. Modelado Bayesiano en Forensic Data Science y Simulación de Datos Sintéticos

Sí, es totalmente posible (y muy recomendable) **simular datos sintéticos** para profundizar en la parte bayesiana, especialmente cuando: no hay acceso a datos reales por privacidad o cadena de custodia, se requiere evaluar desempeño bajo condiciones controladas, se quiere estudiar calibración, sesgos, y sensibilidad a supuestos.

5.1. Marco bayesiano básico: hipótesis y evidencia

Sea E la evidencia observada (p. ej. un vector de características extraídas de una huella, voz, ADN, espectro, etc.). En forense suele compararse:

- H_p: "la evidencia proviene de la fuente del sospechoso" (hipótesis de fiscalía),
- H_d: "la evidencia proviene de otra fuente" (hipótesis alternativa / defensa).

La cantidad central es la **razón de verosimilitud** (Likelihood Ratio):

$$LR(E) = \frac{p(E \mid H_p)}{p(E \mid H_d)}. \tag{3}$$

Con probabilidades a priori $P(H_p)$ y $P(H_d)$, el **odds posterior** es:

$$\frac{P(H_p \mid E)}{P(H_d \mid E)} \;=\; LR(E) \cdot \frac{P(H_p)}{P(H_d)}. \tag{4}$$

Idea clave para simulación sintética: Para simular datos sintéticos necesitas especificar modelos generativos bajo cada hipótesis:

$$E \sim p(\cdot \mid H_p) \quad \text{y} \quad E \sim p(\cdot \mid H_d).$$

Luego puedes: generar muchos casos $E^{(1)}, \ldots, E^{(N)}$, calcular $LR(E^{(i)})$, evaluar error, calibración, robustez, e interpretabilidad.

5.2. Modelo sintético 1: Evidencia univariada (caso didáctico)

Supón que la evidencia es escalar $E \in \mathbb{R}$ (p. ej. una medida resumen de una señal).

5.3. Modelo

$$E \mid H_p \sim \mathcal{N}(\mu_p, \sigma^2), \tag{5}$$
$$E \mid H_d \sim \mathcal{N}(\mu_d, \sigma^2). \tag{6}$$

Entonces el LR tiene forma cerrada:

$$LR(E) = \frac{\phi(E; \mu_p, \sigma^2)}{\phi(E; \mu_d, \sigma^2)}, \tag{7}$$

donde $\phi(\cdot; \mu, \sigma^2)$ es la densidad normal. Tomando logaritmo:

$$\log LR(E) = \log \phi(E; \mu_p, \sigma^2) - \log \phi(E; \mu_d, \sigma^2). \tag{8}$$

5.4. Simulación sintética

Elige parámetros (por ejemplo): $\mu_p = 1, \quad \mu_d = 0, \quad \sigma = 1$. Luego genera: N_p muestras de E bajo H_p, N_d muestras de E bajo H_d, y calcula $LR(E)$ para cada muestra.

5.5. Modelo sintético 2: Evidencia multivariada (más realista)

Ahora $E = x \in \mathbb{R}^p$ (vector de características).

5.6. Modelo generativo gaussiano

$$x \mid H_p \sim \mathcal{N}_p(\mu_p, \Sigma_p), \tag{9}$$
$$x \mid H_d \sim \mathcal{N}_p(\mu_d, \Sigma_d). \tag{10}$$

El LR queda:

$$LR(x) = \frac{\mathcal{N}_p(x; \mu_p, \Sigma_p)}{\mathcal{N}_p(x; \mu_d, \Sigma_d)}. \tag{11}$$

Este modelo es útil para estudiar: separación entre clases, efecto de correlaciones, mal-especificación (cuando $\Sigma_p \neq \Sigma_d$), selección de características y PCA.

5.7. Modelo sintético 3: Población (Defense) como mezcla

En muchos contextos forenses, H_d representa una **población** heterogénea. Un modelo más realista es una mezcla:

$$x \mid H_d \sim \sum_{k=1}^{K} \pi_k \mathcal{N}_p(x; \mu_k, \Sigma_k), \qquad \sum_{k=1}^{K} \pi_k = 1. \tag{12}$$

Esto permite simular: subpoblaciones, efectos demográficos (sesgo de muestreo), cambios de dominio (*dataset shift*). En la práctica, $\mu_p, \Sigma_p, \mu_d, \Sigma_d$ son desconocidos. Un enfoque bayesiano asigna priors.

5.8. Prior conjugado (Normal-Inversa-Wishart)

Para el caso multivariado, un prior clásico es:

$$\Sigma \sim \mathcal{IW}(\nu_0, \Lambda_0), \tag{13}$$

$$\mu \mid \Sigma \sim \mathcal{N}_p(\mu_0, \Sigma/\kappa_0). \tag{14}$$

Dado un conjunto de entrenamiento $X = \{x_1, \ldots, x_n\}$, se obtiene el posterior analítico (conjugado) y la predictiva:

$$p(x_{\text{new}} \mid X) = \int p(x_{\text{new}} \mid \mu, \Sigma)\, p(\mu, \Sigma \mid X)\, d\mu\, d\Sigma, \tag{15}$$

que resulta en una distribución tipo t multivariada (en el caso conjugado). Entonces el LR bayesiano puede definirse usando predictivas:

$$LR_{\text{Bayes}}(x) = \frac{p(x \mid X_p, H_p)}{p(x \mid X_d, H_d)}, \tag{16}$$

donde X_p y X_d son datos de entrenamiento bajo cada hipótesis/población.

6. Protocolo de simulación sintética (recomendado)

6.1. Diseño experimental

1. Elegir dimensión p y tamaños $N_{\text{train}}, N_{\text{test}}$.
2. Especificar modelos generativos bajo H_p y H_d (gaussiano o mezcla).
3. Generar conjuntos: X_p^{train}, X_d^{train}, X^{test}.
4. Ajustar el modelo bayesiano (posterior).
5. Calcular $LR_{\text{Bayes}}(x)$ para cada $x \in X^{\text{test}}$.
6. Evaluar: discriminación (ROC/DET usando $\log LR$), calibración (si $\log LR$ está bien escalado), sensibilidad a priors ($\nu_0, \Lambda_0, \kappa_0$), robustez a cambios de población (mezclas en H_d).

Notas prácticas importantes

- **Simular es valioso**, pero hay que declarar qué tan realista es el generador.
- Para forense, es común estudiar $\log_{10} LR$ (más interpretable en reportes).
- Si usas modelos discriminativos (p. ej. regresión logística), la salida no es un LR por defecto; en Bayes, lo natural es ir por predictivas o por modelos generativos.

7. Investigación en Ciencia Forense y Estadística en México

El desarrollo de métodos cuantitativos aplicados a ciencia forense en México es todavía un campo emergente. Sin embargo, existen instituciones académicas y grupos de investigación que trabajan en áreas relacionadas como: antropología forense, genética forense, criminología cuantitativa, análisis de redes criminales, identificación humana. Estas líneas de investigación constituyen la base para el desarrollo de *Forensic Data Science* en el país.

7.1. Universidad Nacional Autónoma de México (UNAM)

La UNAM cuenta con múltiples grupos que trabajan en ciencias forenses. Entre ellos destacan: Instituto de Investigaciones Jurídicas, Instituto de Investigaciones Antropológicas, Escuela Nacional de Antropología e Historia (ENAH). Estas instituciones participan en proyectos de: identificación de restos humanos, análisis de fosas clandestinas, reconstrucción de contextos forenses, desarrollo de metodologías científicas para identificación humana. Investigaciones recientes han resaltado la necesidad de enfoques integrales y cuantitativos para abordar el gran número de cuerpos no identificados en el país. [*forensic-mexico-context*]

7.2. Equipo Mexicano de Antropología Forense (EMAF)

El Equipo Mexicano de Antropología Forense es una organización científica independiente dedicada a: identificación de restos humanos, análisis de fosas clandestinas, apoyo a familias de personas desaparecidas. Su trabajo combina: antropología forense, genética, bases de datos de identificación, análisis estadístico de coincidencias.

7.3. Instituto Nacional de Ciencias Penales

El Instituto Nacional de Ciencias Penales (INACIPE) desarrolla investigación en: criminología, política criminal, análisis de evidencia legal. Este instituto podría beneficiarse de metodologías de *Forensic Data Science*.

7.4. Investigación cuantitativa sobre crimen en México

Aunque no siempre se identifica como ciencia forense, existen investigadores en México que aplican métodos avanzados de ciencia de datos al estudio del crimen.

7.5. Análisis de redes criminales

Investigadores han utilizado: teoría de redes, aprendizaje automático, análisis de grafos, para estudiar fenómenos como: evasión fiscal, redes criminales, tráfico de personas. Estos estudios muestran que los patrones de interacción entre actores criminales pueden ser detectados mediante análisis estructural de redes. [*network-crime-mexico*]

7.6. Crisis forense en México y necesidad de métodos cuantitativos

México enfrenta actualmente una crisis forense significativa. Se estima que decenas de miles de restos humanos permanecen sin identificar en instalaciones forenses del país [*network-crime-mexico*]. Este contexto ha impulsado la necesidad de desarrollar: sistemas de bases de datos forenses, métodos estadísticos para identificación, algoritmos de comparación biométrica, modelos probabilísticos para evidencia genética. El desarrollo de herramientas basadas en ciencia de datos podría contribuir significativamente a mejorar los procesos de identificación humana y análisis de evidencia.

7.7. Oportunidad científica

A diferencia de Europa o Estados Unidos, donde la estadística forense es un campo consolidado, en México existe una gran oportunidad para desarrollar: modelos bayesianos para evaluación de evidencia, análisis de mezclas de ADN, identificación probabilística, análisis de redes criminales. La magnitud de los problemas forenses en el país hace que la integración de ciencia de datos y estadística avanzada sea un área de investigación con alto impacto científico y social.

7.8. Investigación y Datos Abiertos para Forensic Data Science en México

El desarrollo de métodos de *Forensic Data Science* en México puede apoyarse en tres pilares fundamentales: grupos académicos con experiencia en análisis cuantitativo del crimen, instituciones con infraestructura científica relevante, disponibilidad de bases de datos abiertas.

7.9. Investigadores e instituciones cercanas al área

Aunque el campo específico de *forensic statistics* aún es incipiente en México, existen investigadores que trabajan en áreas cercanas como criminología cuantitativa, análisis de redes criminales y estadística aplicada a seguridad pública.

7.10. Centro de Investigación y Docencia Económicas (CIDE)

El CIDE cuenta con investigadores que han desarrollado modelos cuantitativos para estudiar fenómenos criminales en México, incluyendo: análisis estadístico del crimen organizado, modelos econométricos de violencia, análisis espacial del crimen. Estas líneas de investigación utilizan herramientas como: regresión estadística, modelos espaciales, análisis de redes.

8. Bases de datos abiertas en México

México cuenta con varias bases de datos públicas útiles para investigación en ciencia de datos aplicada al crimen.

8.1. Datos Abiertos del Gobierno de México

El portal nacional de datos abiertos ofrece información sobre: incidencia delictiva, registros policiales, información geográfica del crimen. Estas bases de datos permiten realizar: análisis temporal de criminalidad, análisis espacial del crimen, detección de patrones.

8.2. Secretariado Ejecutivo del Sistema Nacional de Seguridad Pública

Esta institución publica datos mensuales de incidencia delictiva. Las variables incluyen: tipo de delito, estado y municipio, fecha del registro. Estos datos se utilizan frecuentemente para: análisis estadístico del crimen, modelos predictivos, estudios de políticas públicas.

8.3. INEGI

El Instituto Nacional de Estadística y Geografía produce varios conjuntos de datos relevantes.

Entre ellos destacan: ENVIPE (Encuesta Nacional de Victimización), registros administrativos de delitos, datos geoespaciales. Estos datos permiten estudiar: subregistro del crimen, patrones de victimización, correlaciones socioeconómicas del delito.

9. Áreas de oportunidad

La combinación de: bases de datos abiertas, métodos bayesianos, aprendizaje automático, análisis de redes criminales; abre la posibilidad de desarrollar en México una línea de investigación sólida en *Forensic Data Science*. Esta área podría contribuir tanto al avance científico como a la mejora de los sistemas de análisis criminal y forense del país.

9.1. Propuesta de Investigación: Bayesian Forensic Data Science en México

El desarrollo de metodologías bayesianas para el análisis de evidencia forense representa una oportunidad científica importante en México. La disponibilidad de datos abiertos sobre criminalidad y la magnitud de los problemas forenses del país hacen posible plantear proyectos de investigación con impacto científico y social.

Objetivo del proyecto

El objetivo general del proyecto es desarrollar modelos bayesianos para el análisis probabilístico de evidencia criminal y patrones delictivos utilizando datos abiertos disponibles en México. Entre los objetivos específicos se encuentran: desarrollar modelos probabilísticos para evaluar evidencia criminal, aplicar métodos bayesianos para análisis de patrones delictivos, integrar técnicas de ciencia de datos y aprendizaje automático.

Problema científico

En muchos sistemas de justicia, la interpretación de evidencia se basa en métodos heurísticos o determinísticos.

Un enfoque bayesiano permite cuantificar explícitamente la incertidumbre. En este contexto, la evidencia E se analiza comparando dos hipótesis:

- H_p: la evidencia es consistente con la hipótesis de la fiscalía,
- H_d: la evidencia es consistente con una hipótesis alternativa.

El peso de la evidencia puede expresarse mediante la razón de verosimilitud:

$$LR(E) = \frac{P(E|H_p)}{P(E|H_d)} \tag{17}$$

Este enfoque es ampliamente utilizado en genética forense y análisis probabilístico de evidencia.

9.2. Datos

El proyecto podría utilizar fuentes de datos abiertas disponibles en México, tales como: incidencia delictiva del Secretariado Ejecutivo del Sistema Nacional de Seguridad Pública, encuestas de victimización del INEGI, datos geoespaciales sobre criminalidad. Estos conjuntos de datos permiten estudiar patrones espaciales y temporales del crimen.

9.3. Metodología

La metodología propuesta consta de varias etapas.

Simulación de datos sintéticos

Antes de aplicar modelos a datos reales, se pueden generar conjuntos de datos sintéticos utilizando modelos probabilísticos. Por ejemplo, se pueden generar vectores de características x bajo dos distribuciones:

$$x|H_p \sim \mathcal{N}(\mu_p, \Sigma_p) \tag{18}$$

$$x|H_d \sim \mathcal{N}(\mu_d, \Sigma_d) \tag{19}$$

Estos datos permiten evaluar el comportamiento de los modelos bajo condiciones controladas.

Reducción de dimensionalidad

Cuando los datos tienen muchas variables, se pueden aplicar técnicas como Análisis de Componentes Principales (PCA). Sea X la matriz de datos estandarizada. PCA busca una transformación lineal:

$$T = XW \tag{20}$$

donde W contiene los vectores propios de la matriz de covarianza.

Modelos bayesianos

Los parámetros del modelo pueden estimarse usando inferencia bayesiana. Por ejemplo, si las medias son desconocidas, se pueden utilizar priors normales:

$$\mu_p \sim \mathcal{N}(\mu_0, \tau^2 I) \tag{21}$$
$$\mu_d \sim \mathcal{N}(\mu_0, \tau^2 I) \tag{22}$$

La distribución posterior se obtiene mediante el teorema de Bayes:

$$P(\theta|X) \propto P(X|\theta)P(\theta) \tag{23}$$

9.4. Resultados esperados

El proyecto podría producir: modelos probabilísticos para evaluación de evidencia, algoritmos para detección de patrones criminales, herramientas de ciencia de datos aplicadas a criminología.

9.5. Impacto

El desarrollo de herramientas de *Forensic Data Science* en México podría contribuir a: mejorar el análisis de evidencia criminal, apoyar investigaciones forenses, desarrollar capacidades científicas en análisis cuantitativo del crimen. Además, este tipo de investigación puede fortalecer la integración entre estadística, ciencia de datos y ciencias forenses en el país.

Experimento completo en R: Simulación Bayesiana Forense con Likelihood Ratios

Esta sección propone un experimento reproducible para: simular evidencia sintética bajo dos hipótesis (H_p y H_d), ajustar modelos bayesianos generativos, calcular *Likelihood Ratios* (LR) vía densidades predictivas, evaluar desempeño (ROC) y calibración (Brier / ECE) usando $\log LR$.

Planteamiento probabilístico

Sea $x \in \mathbb{R}^p$ un vector de rasgos extraídos de evidencia. Modelos generativos:

$$x \mid H_p \sim \mathcal{N}_p(\mu_p, \Sigma_p), \tag{24}$$
$$x \mid H_d \sim \mathcal{N}_p(\mu_d, \Sigma_d). \tag{25}$$

En un enfoque bayesiano, μ y Σ son desconocidos y se les asigna un prior conjugado *Normal-Inversa-Wishart* (NIW):

$$\Sigma \sim \mathcal{IW}(\nu_0, \Lambda_0), \tag{26}$$
$$\mu \mid \Sigma \sim \mathcal{N}_p(\mu_0, \Sigma/\kappa_0). \tag{27}$$

La distribución predictiva posterior para una nueva observación x (con NIW) es una t multivariada:

$$p(x \mid X) = t_{\nu_n - p + 1}\left(x; \mu_n,\ \frac{\kappa_n + 1}{\kappa_n(\nu_n - p + 1)}\Lambda_n\right),$$

donde $(\mu_n, \kappa_n, \nu_n, \Lambda_n)$ son los hiperparámetros posteriores. Entonces, para una evidencia x:

$$LR_{\text{Bayes}}(x) = \frac{p(x \mid X_p, H_p)}{p(x \mid X_d, H_d)}. \tag{28}$$

9.6. Diseño del experimento

1. Elegir dimensión p y separación entre clases (control de dificultad).
2. Simular conjuntos de entrenamiento: X_p^{train} y X_d^{train}.
3. Simular conjunto de prueba mezclado con etiqueta verdadera $y \in \{0, 1\}$.
4. Ajustar NIW por clase y calcular $LR_{\text{Bayes}}(x)$ para cada caso.
5. Evaluar: discriminación: ROC-AUC usando $s(x) = \log LR(x)$, calibración: convertir s a probabilidad y calcular Brier/ECE, estabilidad: repetir con distintas semillas o escenarios.

Código R (listo para copiar y ejecutar)

```
# ============================================================
# Bayesian Forensic Simulation: NIW + predictive t + LR
# ============================================================

# Paquetes (solo base + MASS para mvrnorm)
if (!requireNamespace("MASS", quietly = TRUE)) install.packages("MASS")
library(MASS)

set.seed(123)

# ------------------------------
# Utilidades matematicas
# ------------------------------

# log densidad de t multivariada: x ~ mvt(df, mean, Sigma)
log_dmvt <- function(x, mean, Sigma, df) {
  # x: vector p
  # mean: vector p
  # Sigma: matriz p x p (escala)
  p <- length(x)
  xc <- matrix(x - mean, ncol = 1)
  # estabilizar: usar chol + solve triangular
  R <- chol(Sigma)
  # Mahalanobis: (x-mean)' Sigma^{-1} (x-mean)
  z <- backsolve(R, xc, transpose = TRUE)
  quad <- sum(z^2)
  logdet <- 2 * sum(log(diag(R)))

  # log constante
  # log Gamma((df+p)/2) - log Gamma(df/2) - (p/2)log(df*pi) - 0.5 log|Sigma|
  lc <- lgamma((df + p) / 2) - lgamma(df / 2) - (p / 2) * log(df * pi) - 0.5 * logdet
  # log kernel
  lk <- -((df + p) / 2) * log1p(quad / df)
  lc + lk
}

# NIW posterior update
niw_posterior <- function(X, mu0, kappa0, nu0, Lambda0) {
  # X: n x p
  X <- as.matrix(X)
  n <- nrow(X)
  p <- ncol(X)
  xbar <- colMeans(X)
  # scatter
  S <- t(X - matrix(xbar, n, p, byrow=TRUE)) %*% (X - matrix(xbar, n, p, byrow=TRUE))

  kappa_n <- kappa0 + n
  nu_n <- nu0 + n
  mu_n <- (kappa0 * mu0 + n * xbar) / kappa_n

  # Lambda_n = Lambda0 + S + (kappa0*n/kappa_n) (xbar-mu0)(xbar-mu0)'
  d <- matrix(xbar - mu0, ncol=1)
  Lambda_n <- Lambda0 + S + (kappa0 * n / kappa_n) * (d %*% t(d))

  list(mu = mu_n, kappa = kappa_n, nu = nu_n, Lambda = Lambda_n)
}

# predictive t parameters from NIW posterior
predictive_params <- function(post) {
  mu_n <- post$mu
  kappa_n <- post$kappa
  nu_n <- post$nu
  Lambda_n <- post$Lambda
```

```
  p <- length(mu_n)
  df <- nu_n - p + 1
  # scale matrix for multivariate t
  Sigma <- (kappa_n + 1) / (kappa_n * df) * Lambda_n
  list(mean = mu_n, Sigma = Sigma, df = df)
}

# Calibracion: convertir logLR a prob via logistic con prior odds (aqui 0.5/0.5)
logit <- function(z) 1/(1+exp(-z))

# ECE (Expected Calibration Error) para clasificacion binaria
ece_binary <- function(p_hat, y, bins = 10) {
  stopifnot(length(p_hat) == length(y))
  breaks <- seq(0, 1, length.out = bins + 1)
  bin_id <- cut(p_hat, breaks = breaks, include.lowest = TRUE, labels = FALSE)
  ece <- 0
  n <- length(y)
  for (b in 1:bins) {
    idx <- which(bin_id == b)
    if (length(idx) == 0) next
    acc <- mean(y[idx])
    conf <- mean(p_hat[idx])
    ece <- ece + (length(idx)/n) * abs(acc - conf)
  }
  ece
}

# AUC ROC (implementacion simple por ranking)
auc_roc <- function(score, y) {
  # y in {0,1}; score mayor => predice 1
  r <- rank(score, ties.method = "average")
  n1 <- sum(y == 1)
  n0 <- sum(y == 0)
  # estadistico U de Mann-Whitney
  U <- sum(r[y == 1]) - n1*(n1+1)/2
  U / (n1*n0)
}

# ------------------------------
# 1) Escenario sintetico controlable
# ------------------------------
p <- 5
n_train <- 200
n_test  <- 500

# Separacion entre clases (sube esto para problema mas facil)
delta <- 0.8

mu_p_true <- rep(delta, p)
mu_d_true <- rep(0, p)

# Covarianzas verdaderas (puedes jugar con esto)
Sigma_p_true <- diag(p)
Sigma_d_true <- diag(p)

Xp_train <- MASS::mvrnorm(n_train, mu = mu_p_true, Sigma = Sigma_p_true)
Xd_train <- MASS::mvrnorm(n_train, mu = mu_d_true, Sigma = Sigma_d_true)

# Test mezclado
y_test <- rbinom(n_test, 1, 0.5)
X_test <- matrix(NA, n_test, p)
for (i in 1:n_test) {
  if (y_test[i] == 1) X_test[i,] <- MASS::mvrnorm(1, mu_p_true, Sigma_p_true)
  if (y_test[i] == 0) X_test[i,] <- MASS::mvrnorm(1, mu_d_true, Sigma_d_true)
}
```

```
# ------------------------------
# 2) Priors NIW (elige priors debiles)
# ------------------------------
mu0 <- rep(0, p)
kappa0 <- 0.01
nu0 <- p + 2
Lambda0 <- diag(p)

post_p <- niw_posterior(Xp_train, mu0, kappa0, nu0, Lambda0)
post_d <- niw_posterior(Xd_train, mu0, kappa0, nu0, Lambda0)

pred_p <- predictive_params(post_p)
pred_d <- predictive_params(post_d)

# ------------------------------
# 3) Calcular LR bayesiano para cada x_test
# ------------------------------
logLR <- numeric(n_test)
for (i in 1:n_test) {
  lp <- log_dmvt(X_test[i,], pred_p$mean, pred_p$Sigma, pred_p$df)
  ld <- log_dmvt(X_test[i,], pred_d$mean, pred_d$Sigma, pred_d$df)
  logLR[i] <- lp - ld
}

# Convertir a probabilidad con prior 0.5 (odds=1): P(Hp|x)= logistic(logLR)
p_hat <- logit(logLR)

# ------------------------------
# 4) Evaluacion
# ------------------------------
auc <- auc_roc(logLR, y_test)
brier <- mean((p_hat - y_test)^2)
ece <- ece_binary(p_hat, y_test, bins = 10)

cat("AUC (ROC)        =", round(auc, 4), "\n")
cat("Brier score      =", round(brier, 4), "\n")
cat("ECE (10 bins)    =", round(ece, 4), "\n")

# ------------------------------
# 5) Graficas utiles
# ------------------------------
par(mfrow=c(1,3))

# (i) hist logLR por clase
hist(logLR[y_test==0], breaks=30, main="logLR (y=0)", xlab="logLR")
hist(logLR[y_test==1], breaks=30, main="logLR (y=1)", xlab="logLR")

# (ii) calibration plot (reliability diagram)
bins <- 10
breaks <- seq(0,1,length.out=bins+1)
bin_id <- cut(p_hat, breaks=breaks, include.lowest=TRUE, labels=FALSE)
bin_conf <- tapply(p_hat, bin_id, mean)
bin_acc  <- tapply(y_test, bin_id, mean)
plot(bin_conf, bin_acc, xlim=c(0,1), ylim=c(0,1),
     xlab="Confianza promedio", ylab="Frecuencia y=1",
     main="Calibration (10 bins)")
abline(0,1)
```

Cómo interpretar los resultados

AUC: mide separación usando $s(x) = \log LR(x)$. Si $AUC \approx 0{,}5$, el problema es indistinguible; si se acerca a 1, hay buena discriminación. **Brier**: error cuadrático medio de probabilidades. Penaliza mala calibración. **ECE**: desviación promedio ponderada entre confianza y frecuencia real.

Extensiones naturales (para acercarte a un caso real)

Población heterogénea en H_d: reemplazar H_d por una mezcla gaussiana y comparar contra NIW (mis-especificación). **Alta dimensión**: aumentar p y aplicar PCA antes del modelado; estudiar el efecto sobre LR y calibración. **Cambio de dominio**: entrenar con (μ_d, Σ_d) y probar con una población distinta; observar degradación y sesgos.

10. Roles posibles para un especialista en estadística forense

Un experto en métodos estadísticos y ciencia de datos aplicados al ámbito forense puede desempeñar varios tipos de funciones.

10.1. Perito estadístico

En muchos sistemas judiciales existe la figura del *perito*, es decir, un especialista que proporciona análisis técnico sobre evidencia científica.

Un estadístico forense podría: evaluar probabilísticamente evidencia científica, analizar coincidencias de evidencia (por ejemplo ADN o biometría), evaluar la fuerza estadística de la evidencia presentada en un juicio, elaborar informes técnicos para tribunales. Este rol es común en países donde la *forensic statistics* está consolidada.

10.2. Consultor en análisis de datos criminales

Las fiscalías y dependencias de seguridad generan grandes volúmenes de datos relacionados con: reportes policiales, registros de delitos, datos geoespaciales, evidencia digital. Un especialista en ciencia de datos puede desarrollar modelos para: detección de patrones delictivos, análisis espacial del crimen, predicción de eventos criminales, análisis de redes criminales.

10.3. Asesor en laboratorios forenses

Los laboratorios forenses analizan evidencia física como: ADN, huellas dactilares, evidencia digital, análisis de voz. Los métodos estadísticos pueden utilizarse para: estimar probabilidades de coincidencia, evaluar incertidumbre en las mediciones, desarrollar modelos probabilísticos para identificación.

10.4. Desarrollo de software analítico

Otra posibilidad consiste en desarrollar herramientas computacionales para análisis de evidencia o datos criminales. Estas herramientas pueden incluir: software para análisis probabilístico de evidencia, plataformas de análisis espacial del crimen, sistemas de análisis de redes criminales.

11. Principales investigadores

El campo de la estadística forense ha sido desarrollado principalmente por un pequeño grupo de investigadores que han integrado métodos estadísticos rigurosos en la interpretación de evidencia científica. Sus contribuciones han establecido los fundamentos teóricos y metodológicos que actualmente se utilizan en laboratorios forenses y tribunales.

- Colin G. G. Aitken, es uno de los pioneros en la aplicación de estadística bayesiana al análisis de evidencia forense. Sus contribuciones incluyen: desarrollo del marco probabilístico para evaluación de evidencia, formalización del uso de *likelihood ratios*, desarrollo de métodos estadísticos aplicados a ADN forense. Uno de sus libros más influyentes es: *Statistics and the Evaluation of Evidence for Forensic Scientists*. Este trabajo estableció las bases modernas para el análisis probabilístico de evidencia.

- Franco Taroni, ha contribuido significativamente al desarrollo de métodos probabilísticos y redes bayesianas aplicadas a ciencia forense. Entre sus contribuciones se encuentran: uso de redes bayesianas para modelar evidencia compleja, integración de múltiples fuentes de evidencia, desarrollo de metodologías probabilísticas para tribunales. Uno de sus trabajos más importantes es: *Bayesian Networks and Probabilistic Inference in Forensic Science*. Este libro presenta herramientas para modelar relaciones probabilísticas entre distintos tipos de evidencia.

- Alex Biedermann, es uno de los investigadores más activos en el desarrollo contemporáneo de estadística forense. Su trabajo se enfoca en: modelado bayesiano de evidencia, interpretación probabilística de resultados forenses, desarrollo de marcos teóricos para la evaluación de evidencia. Ha trabajado extensamente en la Universidad de Lausana, uno de los centros más importantes de investigación en ciencias forenses.

- David Lucy, ha realizado contribuciones importantes en: análisis estadístico de huellas dactilares, evaluación de incertidumbre en identificación biométrica, modelos probabilísticos aplicados a evidencia física. Sus trabajos han sido influyentes en la discusión sobre la confiabilidad de métodos tradicionales de identificación.

12. Centros de investigación importantes

El desarrollo de la estadística forense ha estado fuertemente asociado con algunos centros académicos y laboratorios.

- University of Lausanne en Suiza alberga uno de los programas más importantes de investigación en ciencia forense. En este centro se desarrollan investigaciones sobre: análisis probabilístico de evidencia, redes bayesianas, integración de múltiples fuentes de evidencia.
- Netherlands Forensic Institute de los Países Bajos es uno de los laboratorios más avanzados del mundo. En este instituto se utilizan métodos estadísticos avanzados para: análisis de ADN, biometría, evidencia digital.
- Universidad de Edimburgo ha sido un centro importante en el desarrollo de estadística aplicada a evidencia forense. Investigadores en esta institución han trabajado en: modelos bayesianos, análisis de ADN, evaluación de evidencia biométrica.

13. Plan de trabajo

El establecimiento de una línea de investigación en *Bayesian Forensic Data Science* requiere una estrategia gradual que combine desarrollo metodológico, generación de datos sintéticos, publicaciones académicas y colaboración con instituciones del sistema de justicia. Se propone una estrategia en cuatro etapas que puede desarrollarse en un horizonte de aproximadamente cinco años.

13.1. Fase I: Fundamentos metodológicos (Año 1)

La primera etapa consiste en desarrollar la base teórica y computacional del programa de investigación.

Objetivos

Desarrollar modelos bayesianos para evaluación de evidencia, diseñar simulaciones sintéticas que permitan estudiar el comportamiento de los modelos, establecer un marco computacional reproducible en R.

Líneas metodológicas iniciales

Se pueden explorar problemas fundamentales como: Calibración de *likelihood ratios*, comparación entre modelos generativos y discriminativos, impacto de la dimensionalidad en la evaluación de evidencia.

Resultados esperados

Artículos metodológicos en estadística aplicada, repositorios abiertos con código reproducible, formación de estudiantes de licenciatura o maestría.

13.2. Fase II: Aplicación a problemas criminales (Años 2–3)

En esta etapa se integran datos reales provenientes de fuentes abiertas.

Posibles datasets

Incidencia delictiva (Secretariado Ejecutivo del Sistema Nacional de Seguridad Pública), encuestas de victimización (INEGI), datos geoespaciales del crimen.

Problemas de investigación

Entre los problemas que pueden estudiarse se encuentran: análisis espacial del crimen, detección de patrones criminales, análisis de redes delictivas. Se pueden utilizar modelos como: procesos puntuales espaciales, modelos bayesianos jerárquicos, modelos de mezcla.

13.3. Fase III: Colaboración institucional (Años 3–4)

Una vez desarrolladas herramientas metodológicas, se pueden establecer colaboraciones con instituciones relacionadas con el análisis forense.

Instituciones potenciales

Fiscalías estatales, institutos de ciencias forenses, laboratorios de genética forense. Las colaboraciones pueden enfocarse en: desarrollo de herramientas analíticas, capacitación en análisis de datos, evaluación estadística de evidencia.

13.4. Fase IV: Consolidación y transferencia (Años 4–5)

La etapa final busca consolidar la línea de investigación y transferir los resultados a aplicaciones prácticas.

Resultados posibles

Desarrollo de software analítico, consultoría técnica para instituciones públicas, creación de programas de formación en ciencia de datos forense.

13.5. Impacto académico y profesional

El desarrollo de una línea de investigación en *Forensic Data Science* puede generar impacto en múltiples dimensiones. Impacto académico: publicaciones en estadística aplicada, dirección de tesis en ciencia de datos, colaboración interdisciplinaria.

Impacto profesional

Asesoría técnica para instituciones públicas, desarrollo de herramientas analíticas, participación en proyectos de investigación aplicada.