



# Análisis de Regresión Lineal

## Universidad Autónoma de la Ciudad de México

*Casa Libertad*

Carlos E. Martínez Rodríguez

[carlos.martinez@uacm.edu.mx](mailto:carlos.martinez@uacm.edu.mx)

Academia de Matemáticas - Modelación Matemática  
Colegio de Ciencia y Tecnología

Semestre 2019-II



### 3. Análisis de Regresión Lineal (RL)

3.1 Regresión Lineal Simple (RLS)

3.2 Método de Mínimos Cuadrados

3.3 Propiedades de los Estimadores  $\hat{\beta}_0$  y  $\hat{\beta}_1$

3.4 Prueba de Hipótesis en RLS

Estimación de Intervalos en RLS

Predicción

Coeficiente de Determinación



## Descripción

### Nota

- ▶ *En muchos problemas hay dos o más variables relacionadas, para medir el grado de relación se utiliza el **análisis de regresión**.*
- ▶ *Supongamos que se tiene una única variable dependiente,  $y$ , y varias variables independientes,  $x_1, x_2, \dots, x_n$ .*
- ▶ *La variable  $y$  es una variable aleatoria, y las variables independientes pueden ser distribuidas independiente o conjuntamente.*

## RLS

- ▶ A la relación entre estas variables se le denomina modelo regresión de  $y$  en  $x_1, x_2, \dots, x_n$ , por ejemplo  $y = \phi(x_1, x_2, \dots, x_n)$ , lo que se busca es una función que mejor aproxime a  $\phi(\cdot)$ .

Supongamos que de momento solamente se tienen una variable independiente  $x$ , para la variable de respuesta  $y$ . Y supongamos que la relación que hay entre  $x$  y  $y$  es una línea recta, y que para cada observación de  $x$ ,  $y$  es una variable aleatoria.

El valor esperado de  $y$  para cada valor de  $x$  es

$$E(y|x) = \beta_0 + \beta_1 x \quad (1)$$

$\beta_0$  es la ordenada al origen y  $\beta_1$  la pendiente de la recta en



## Mínimos Cuadrados

Supongamos que cada observación  $y$  se puede describir por el modelo

$$y = \beta_0 + \beta_1 x + \epsilon \quad (2)$$

donde  $\epsilon$  es un error aleatorio con media cero y varianza  $\sigma^2$ . Para cada valor  $y_i$  se tiene  $\epsilon_i$  variables aleatorias no correlacionadas, cuando se incluyen en el modelo 2, este se le llama *modelo de regresión lineal simple*.

Suponga que se tienen  $n$  pares de observaciones  $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ , estos datos pueden utilizarse para estimar los valores de  $\beta_0$  y  $\beta_1$ . Esta estimación es por el **métodos de mínimos cuadrados**.



## Mínimos Cuadrados

Entonces la ecuación 2 se puede reescribir como

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i, \text{ para } i = 1, 2, \dots, n. \quad (3)$$

Si consideramos la suma de los cuadrados de los errores aleatorios, es decir, el cuadrado de la diferencia entre las observaciones con la recta de regresión

$$L = \sum_{i=1}^n \epsilon^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \quad (4)$$



## Mínimos Cuadrados

Para obtener los estimadores por mínimos cuadrados de  $\beta_0$  y  $\beta_1$ ,  $\hat{\beta}_0$  y  $\hat{\beta}_1$ , es preciso calcular las derivadas parciales con respecto a  $\beta_0$  y  $\beta_1$ , igualar a cero y resolver el sistema de ecuaciones lineales resultante:

$$\frac{\partial L}{\partial \beta_0} = 0$$

$$\frac{\partial L}{\partial \beta_1} = 0$$

evaluando en  $\hat{\beta}_0$  y  $\hat{\beta}_1$ , se tiene



## Mínimos Cuadrados

$$-2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$

$$-2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) x_i = 0$$

simplificando

$$n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n x_i = \sum_{i=1}^n y_i$$

$$\hat{\beta}_0 \sum_{i=1}^n x_i + \hat{\beta}_1 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i$$





## Mínimos Cuadrados

Las ecuaciones anteriores se les denominan *ecuaciones normales de mínimos cuadrados* con solución

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \quad (5)$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i - \frac{1}{n} (\sum_{i=1}^n y_i) (\sum_{i=1}^n x_i)}{\sum_{i=1}^n x_i^2 - \frac{1}{n} (\sum_{i=1}^n x_i)^2} \quad (6)$$

entonces el modelo de regresión lineal simple ajustado es

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x \quad (7)$$



## Mínimos Cuadrados

Se introduce la siguiente notación

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - \frac{1}{n} \left( \sum_{i=1}^n x_i \right)^2 \quad (8)$$

$$S_{xy} = \sum_{i=1}^n y_i (x_i - \bar{x}) = \sum_{i=1}^n x_i y_i - \frac{1}{n} \left( \sum_{i=1}^n x_i \right) \left( \sum_{i=1}^n y_i \right) \quad (9)$$

y por tanto

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} \quad (10)$$



## Propiedades de los estimadores

### Nota



## Propiedades de los estimadores

### Nota

- ▶ *Las propiedades estadísticas de los estimadores de mínimos cuadrados son útiles para evaluar la suficiencia del modelo.*
- ▶ *Dado que  $\hat{\beta}_0$  y  $\hat{\beta}_1$  son combinaciones lineales de las variables aleatorias  $y_i$ , también resultan ser variables aleatorias.*

A saber

$$E(\hat{\beta}_1) = E\left(\frac{S_{xy}}{S_{xx}}\right) = \frac{1}{S_{xx}} E\left(\sum_{i=1}^n y_i (x_i - \bar{x})\right)$$



## Propiedades de los estimadores

$$\begin{aligned}
 &= \frac{1}{S_{xx}} E \left( \sum_{i=1}^n (\beta_0 + \beta_1 x_i + \epsilon_i) (x_i - \bar{x}) \right) \\
 &= \frac{1}{S_{xx}} \left[ \beta_0 E \left( \sum_{k=1}^n (x_k - \bar{x}) \right) + E \left( \beta_1 \sum_{k=1}^n x_k (x_k - \bar{x}) \right) \right. \\
 &\quad \left. + E \left( \sum_{k=1}^n \epsilon_k (x_k - \bar{x}) \right) \right] = \frac{1}{S_{xx}} \beta_1 S_{xx} = \beta_1
 \end{aligned}$$

por lo tanto

$$E(\hat{\beta}_1) = \beta_1$$

(11) 



## Propiedades de los estimadores

### Nota

*Es decir,  $\hat{\beta}_1$  es un estimador insesgado.*

Ahora calculemos la varianza:

$$\begin{aligned}
 V(\hat{\beta}_1) &= V\left(\frac{S_{xy}}{S_{xx}}\right) = \frac{1}{S_{xx}^2} V\left(\sum_{k=1}^n y_k (x_k - \bar{x})\right) \\
 &= \frac{1}{S_{xx}^2} \sum_{k=1}^n V(y_k (x_k - \bar{x})) = \frac{1}{S_{xx}^2} \sum_{k=1}^n \sigma^2 (x_k - \bar{x})^2 \\
 &= \frac{\sigma^2}{S_{xx}^2} \sum_{k=1}^n (x_k - \bar{x})^2 = \frac{\sigma^2}{S_{xx}}
 \end{aligned}$$



## Propiedades de los estimadores

por lo tanto

$$V(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}} \quad (12)$$

### Proposición

$$E(\hat{\beta}_0) = \beta_0,$$

$$V(\hat{\beta}_0) = \sigma^2 \left( \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right),$$

$$\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = -\frac{\sigma^2 \bar{x}}{S_{xx}}.$$



## Propiedades de los estimadores

Para estimar  $\sigma^2$  es preciso definir la diferencia entre la observación  $y_k$ , y el valor predicho  $\hat{y}_k$ , es decir

$e_k = y_k - \hat{y}_k$ , se le denomina **residuo**.

La suma de los cuadrados de los errores de los residuos, *suma de cuadrados del error*

$$SC_E = \sum_{k=1}^n e_k^2 = \sum_{k=1}^n (y_k - \hat{y}_k)^2 \quad (13)$$





## Propiedades de los estimadores

sustituyendo  $\hat{y}_k = \hat{\beta}_0 + \hat{\beta}_1 x_k$  se obtiene

$$SC_E = \sum_{k=1}^n y_k^2 - n\bar{y}^2 - \hat{\beta}_1 S_{xy} = S_{yy} - \hat{\beta}_1 S_{xy},$$

$$E(SC_E) = (n-2)\sigma^2, \text{ por lo tanto}$$

$$\hat{\sigma}^2 = \frac{SC_E}{n-2} = MC_E \text{ es un estimador insesgado de } \sigma^2.$$



## Prueba de Hipótesis

- ▶ Para evaluar la suficiencia del modelo de regresión lineal simple, es necesario llevar a cabo una prueba de hipótesis respecto de los parámetros del modelo así como de la construcción de intervalos de confianza.
- ▶ Para poder realizar la prueba de hipótesis sobre la pendiente y la ordenada al origen de la recta de regresión es necesario hacer el supuesto de que el error  $\epsilon_i$  se distribuye normalmente, es decir  $\epsilon_i \sim N(0, \sigma^2)$ .



## Prueba de Hipótesis

Suponga que se desea probar la hipótesis de que la pendiente es igual a una constante,  $\beta_{0,1}$  las hipótesis Nula y Alternativa son:

$$H_0: \beta_1 = \beta_{1,0},$$

$$H_1: \beta_1 \neq \beta_{1,0}.$$

donde dado que las  $\epsilon_i \sim N(0, \sigma^2)$ , se tiene que  $y_i$  son variables aleatorias normales  $N(\beta_0 + \beta_1 x_1, \sigma^2)$ . De las ecuaciones (5) se desprende que  $\hat{\beta}_1$  es combinación lineal de variables aleatorias normales independientes, es decir,  $\hat{\beta}_1 \sim N(\beta_1, \sigma^2/S_{xx})$ , recordar las ecuaciones (11) y (12).



## Prueba de Hipótesis

Entonces se tiene que el estadístico de prueba apropiado es

$$t_0 = \frac{\hat{\beta}_1 - \hat{\beta}_{1,0}}{\sqrt{MC_E / S_{xx}}} \quad (14)$$

que se distribuye  $t$  con  $n - 2$  grados de libertad bajo

$H_0 : \beta_1 = \beta_{1,0}$ . Se rechaza  $H_0$  si

$$|t_0| > t_{\alpha/2, n-2}. \quad (15)$$



## Prueba de Hipótesis

Para  $\beta_0$  se puede proceder de manera análoga para

$$H_0 : \beta_0 = \beta_{0,0},$$

$$H_1 : \beta_0 \neq \beta_{0,0},$$

con  $\hat{\beta}_0 \sim N\left(\beta_0, \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)\right)$ , por lo tanto

$$t_0 = \frac{\hat{\beta}_0 - \beta_{0,0}}{MC_E \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}, \quad (16)$$

con el que rechazamos la hipótesis nula si

$$|t_0| > t_{\alpha/2, n-2}. \quad (17)$$



## Prueba de Hipótesis

- ▶ No rechazar  $H_0 : \beta_1 = 0$  es equivalente a decir que no hay relación lineal entre  $x$  y  $y$ .
- ▶ Alternativamente, si  $H_0 : \beta_1 = 0$  se rechaza, esto implica que  $x$  explica la variabilidad de  $y$ , es decir, podríamos significar que la línea recta es el modelo adecuado.

El procedimiento de prueba para  $H_0 : \beta_1 = 0$  puede realizarse de la siguiente manera:

$$S_{yy} = \sum_{k=1}^n (y_k - \bar{y})^2 = \sum_{k=1}^n (\hat{y}_k - \bar{y})^2 + \sum_{k=1}^n (y_k - \hat{y}_k)^2$$



## Prueba de Hipótesis

$$\begin{aligned}
 S_{yy} &= \sum_{k=1}^n (y_k - \bar{y})^2 = \sum_{k=1}^n (y_k - \hat{y}_k + \hat{y}_k - \bar{y})^2 \\
 &= \sum_{k=1}^n [(\hat{y}_k - \bar{y}) + (y_k - \hat{y}_k)]^2 \\
 &= \sum_{k=1}^n \left[ (\hat{y}_k - \bar{y})^2 + 2(\hat{y}_k - \bar{y})(y_k - \hat{y}_k) + (y_k - \hat{y}_k)^2 \right] \\
 &= \sum_{k=1}^n (\hat{y}_k - \bar{y})^2 + 2 \sum_{k=1}^n (\hat{y}_k - \bar{y})(y_k - \hat{y}_k) + \sum_{k=1}^n (y_k - \hat{y}_k)^2
 \end{aligned}$$



## Prueba de Hipótesis

$$\begin{aligned}
 \sum_{k=1}^n (\hat{y}_k - \bar{y}) (y_k - \hat{y}_k) &= \sum_{k=1}^n \hat{y}_k (y_k - \hat{y}_k) - \sum_{k=1}^n \bar{y} (y_k - \hat{y}_k) \\
 &= \sum_{k=1}^n \hat{y}_k (y_k - \hat{y}_k) - \bar{y} \sum_{k=1}^n (y_k - \hat{y}_k) \\
 &= \sum_{k=1}^n (\hat{\beta}_0 + \hat{\beta}_1 x_k) (y_k - \hat{\beta}_0 - \hat{\beta}_1 x_k) - \bar{y} \sum_{k=1}^n (y_k - \hat{\beta}_0 - \hat{\beta}_1 x_k)
 \end{aligned}$$





## Prueba de Hipótesis

$$\begin{aligned}
 &= \sum_{k=1}^n \hat{\beta}_0 \left( y_k - \hat{\beta}_0 - \hat{\beta}_1 x_k \right) + \sum_{k=1}^n \hat{\beta}_1 x_k \left( y_k - \hat{\beta}_0 - \hat{\beta}_1 x_k \right) \\
 &- \bar{y} \sum_{k=1}^n \left( y_k - \hat{\beta}_0 - \hat{\beta}_1 x_k \right) \\
 &= \hat{\beta}_0 \sum_{k=1}^n \left( y_k - \hat{\beta}_0 - \hat{\beta}_1 x_k \right) + \hat{\beta}_1 \sum_{k=1}^n x_k \left( y_k - \hat{\beta}_0 - \hat{\beta}_1 x_k \right) \\
 &- \bar{y} \sum_{k=1}^n \left( y_k - \hat{\beta}_0 - \hat{\beta}_1 x_k \right) = 0 + 0 + 0 = 0.
 \end{aligned}$$



## Prueba de Hipótesis

Por lo tanto, efectivamente se tiene

$$S_{yy} = \sum_{k=1}^n (\hat{y}_k - \bar{y})^2 + \sum_{k=1}^n (y_k - \hat{y}_k)^2, \quad (18)$$

donde se hacen las definiciones

$$SC_E = \sum_{k=1}^n (\hat{y}_k - \bar{y})^2 \cdots \text{Suma de Cuadrados del Error} \quad (19)$$

$$SC_R = \sum_{k=1}^n (y_k - \hat{y}_k)^2 \cdots \text{Suma de Regresión de Cuadrados} \quad (20)$$



## Prueba de Hipótesis

Por lo tanto la ecuación (18) se puede reescribir como

$$S_{yy} = SC_R + SC_E \quad (21)$$

recordemos que  $SC_E = S_{yy} - \hat{\beta}_1 S_{xy}$

$$S_{yy} = SC_R + (S_{yy} - \hat{\beta}_1 S_{xy})$$

$$S_{xy} = \frac{1}{\hat{\beta}_1} SC_R$$

$S_{xy}$  tiene  $n - 1$  grados de libertad y  $SC_R$  y  $SC_E$  tienen 1 y  $n - 2$  grados de libertad respectivamente.



## Prueba de Hipótesis

### Proposición

$$E(SC_R) = \sigma^2 + \beta_1 S_{xx} \quad (22)$$

además,  $SC_E$  y  $SC_R$  son independientes.

Recordemos que  $\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$ . Para  $H_0 : \beta_1 = 0$  verdadera,

$$F_0 = \frac{SC_R/1}{SC_E/(n-2)} = \frac{MC_R}{MC_E}$$

se distribuye  $F_{1,n-2}$ , y se rechazaría  $H_0$  si  $F_0 > F_{\alpha,1,n-2}$ .



## Prueba de Hipótesis

El procedimiento de prueba de hipótesis puede presentarse como la tabla de análisis de varianza siguiente

Fuente de variación	Suma de Cuadrados	Grados de Libertad	Media Cuadrática	$F_0$
------------------------	----------------------	-----------------------	---------------------	-------



## Prueba de Hipótesis

El procedimiento de prueba de hipótesis puede presentarse como la tabla de análisis de varianza siguiente

Fuente de variación	Suma de Cuadrados	Grados de Libertad	Media Cuadrática	$F_0$
Regresión	$SC_R$	1	$MC_R$	$MC_R/MC_E$



## Prueba de Hipótesis

El procedimiento de prueba de hipótesis puede presentarse como la tabla de análisis de varianza siguiente

Fuente de variación	Suma de Cuadrados	Grados de Libertad	Media Cuadrática	$F_0$
Regresión	$SC_R$	1	$MC_R$	$MC_R/MC_E$
Error Residual	$SC_E$	$n - 2$	$MC_E$	



## Prueba de Hipótesis

El procedimiento de prueba de hipótesis puede presentarse como la tabla de análisis de varianza siguiente

Fuente de variación	Suma de Cuadrados	Grados de Libertad	Media Cuadrática	$F_0$
Regresión	$SC_R$	1	$MC_R$	$MC_R/MC_E$
Error Residual	$SC_E$	$n - 2$	$MC_E$	
Total	$S_{yy}$	$n - 1$		





## Prueba de Hipótesis

La prueba para la significación de la regresión puede desarrollarse basándose en la expresión (14), con  $\hat{\beta}_{1,0} = 0$ , es decir



## Prueba de Hipótesis

La prueba para la significación de la regresión puede desarrollarse basándose en la expresión (14), con  $\hat{\beta}_{1,0} = 0$ , es decir

$$t_0 = \frac{\hat{\beta}_1}{\sqrt{MC_E/S_{xx}}} \quad (23)$$

Elevando al cuadrado ambos términos:

$$t_0^2 = \frac{\hat{\beta}_1^2 S_{xx}}{MC_E} = \frac{\hat{\beta}_1 S_{xy}}{MC_E} = \frac{MC_R}{MC_E}$$

UACM Observar que  $t_0^2 = F_0$ , por tanto la prueba que se utiliza para  $t_0$  es la misma que para  $F_0$ .



## Intervalos de Confianza

- ▶ Además de la estimación puntual para los parámetros  $\beta_1$  y  $\beta_0$ , es posible obtener estimaciones del intervalo de confianza de estos parámetros.



## Intervalos de Confianza

- ▶ Además de la estimación puntual para los parámetros  $\beta_1$  y  $\beta_0$ , es posible obtener estimaciones del intervalo de confianza de estos parámetros.
- ▶ El ancho de estos intervalos de confianza es una medida de la calidad total de la recta de regresión.



## Intervalos de Confianza

Si los  $\epsilon_k$  se distribuyen normal e independientemente, entonces

$$\frac{(\hat{\beta}_1 - \beta_1)}{\sqrt{\frac{MC_E}{S_{xx}}}} \quad y \quad \frac{(\hat{\beta}_0 - \beta_0)}{\sqrt{MC_E \left( \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)}}$$

se distribuyen  $t$  con  $n - 2$  grados de libertad.



## Intervalos de Confianza

Si los  $\epsilon_k$  se distribuyen normal e independientemente, entonces

$$\frac{(\hat{\beta}_1 - \beta_1)}{\sqrt{\frac{MC_E}{S_{xx}}}} \quad y \quad \frac{(\hat{\beta}_0 - \beta_0)}{\sqrt{MC_E \left( \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)}}$$

se distribuyen  $t$  con  $n - 2$  grados de libertad. Por tanto un intervalo de confianza de  $100(1 - \alpha)\%$  para  $\beta_1$  está dado por



## Intervalos de Confianza

$$\hat{\beta}_1 - t_{\alpha/2, n-2} \sqrt{\frac{MC_E}{S_{xx}}} \leq \beta_1 \leq \hat{\beta}_1 + t_{\alpha/2, n-2} \sqrt{\frac{MC_E}{S_{xx}}}. \quad (24)$$



## Intervalos de Confianza

$$\hat{\beta}_1 - t_{\alpha/2, n-2} \sqrt{\frac{MC_E}{S_{xx}}} \leq \beta_1 \leq \hat{\beta}_1 + t_{\alpha/2, n-2} \sqrt{\frac{MC_E}{S_{xx}}}. \quad (24)$$

De igual manera, para  $\beta_0$  un intervalo de confianza al  $100(1 - \alpha)\%$  es

$$\hat{\beta}_0 - t_{\alpha/2, n-2} \sqrt{MC_E \left( \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)} \leq \beta_0 \leq \hat{\beta}_0 + t_{\alpha/2, n-2} \sqrt{MC_E \left( \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)} \quad (25)$$





## Predicción

Supongamos que se tiene un valor  $x_0$  de interés, entonces la estimación puntual de este nuevo valor

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0 \quad (26)$$

### Nota

*Esta nueva observación es independiente de las utilizadas para obtener el modelo de regresión, por tanto, el intervalo en torno a la recta de regresión es inapropiado, puesto que se basa únicamente en los datos empleados para ajustar el modelo de regresión.*

*El intervalo de confianza en torno a la recta de regresión se refiere a la respuesta media verdadera  $x = x_0$ , no a observaciones futuras.*



## Predicción

Sea  $y_0$  la observación futura en  $x = x_0$ , y sea  $\hat{y}_0$  dada en la ecuación anterior, el estimador de  $y_0$ . Si se define la variable aleatoria

$$w = y_0 - \hat{y}_0,$$

esta se distribuye normalmente con media cero y varianza

$$V(w) = \sigma^2 \left[ 1 + \frac{1}{n} + \frac{(x - x_0)^2}{S_{xx}} \right]$$

UACM dado que  $y_0$  es independiente de  $\hat{y}_0$ , por lo tanto el intervalo de predicción al nivel  $\alpha$  para futuras observaciones  $x_0$  es

## Predicción

$$\begin{aligned} \hat{y}_0 - t_{\alpha/2, n-2} \sqrt{MC_E \left[ 1 + \frac{1}{n} + \frac{(x - x_0)^2}{S_{xx}} \right]} &\leq y_0 \\ &\leq \hat{y}_0 + t_{\alpha/2, n-2} \sqrt{MC_E \left[ 1 + \frac{1}{n} + \frac{(x - x_0)^2}{S_{xx}} \right]}. \end{aligned}$$



## Coeficiente de Determinación

La cantidad

$$R^2 = \frac{SC_R}{S_{yy}} = 1 - \frac{SC_E}{S_{yy}} \quad (27)$$

se denomina coeficiente de determinación y se utiliza para saber si el modelo de regresión es suficiente o no. Se puede demostrar que  $0 \leq R^2 \leq 1$ , una manera de interpretar este valor es que si  $R^2 = k$ , entonces el modelo de regresión explica el  $k * 100\%$  de la variabilidad en los datos.



## Coeficiente de Determinación

$$R^2$$

- ▶ No mide la magnitud de la pendiente de la recta de regresión
- ▶ Un valor grande de  $R^2$  no implica una pendiente empinada.
- ▶ No mide la suficiencia del modelo.
- ▶ Valores grandes de  $R^2$  no implican necesariamente que el modelo de regresión proporcionará predicciones precisas para futuras observaciones.