

# Curso de Estadística II

## Universidad Autónoma de la Ciudad de México - Casa Libertad

Carlos E. Martínez Rodríguez

Informes: [carlos.martinez@uacm.edu.mx](mailto:carlos.martinez@uacm.edu.mx)

Academia de Matemáticas

Modelación Matemática

Colegio de Ciencia y Tecnología

Semestre 2019-II

## 1 Estimación por intervalos

Intervalos de confianza para dos muestras

Intervalos de confianza para razón de Varianzas

Intervalos de confianza para diferencia de proporciones

## 2 Pruebas de Hipótesis

Tipos de errores

Prueba de Hipótesis para una Proporción Binomial

Inferencias con respecto a la Varianza Poblacional

## 3 Análisis de Regresión Lineal (RL)

Método de Mínimos Cuadrados

Prueba de Hipótesis en RLS

Estimación de Intervalos en RLS

## Intervalos de confianza para $\mu$

Recordemos que  $S^2$  es un estimador insesgado de  $\sigma^2$

### Definición

Sean  $\hat{\theta}_1$  y  $\hat{\theta}_2$  dos estimadores insesgados de  $\theta$ , parámetro poblacional. Si  $\sigma_{\hat{\theta}_1}^2 < \sigma_{\hat{\theta}_2}^2$ , decimos que  $\hat{\theta}_1$  es un estimador más eficaz de  $\theta$  que  $\hat{\theta}_2$ .

Algunas observaciones que es preciso realizar

- a) Para poblaciones normales,  $\bar{X}$  y  $\tilde{X}$  son estimadores insesgados de  $\mu$ , pero con  $\sigma_{\bar{X}}^2 < \sigma_{\tilde{X}}^2$ .
- b) Para las estimaciones por intervalos de  $\theta$ , un intervalo de la forma  $\hat{\theta}_L < \theta < \hat{\theta}_U$ ,  $\hat{\theta}_L$  y  $\hat{\theta}_U$  dependen del valor de  $\hat{\theta}$ .
- c) Para  $\sigma_{\bar{X}}^2 = \frac{\sigma^2}{n}$ , si  $n \rightarrow \infty$ , entonces  $\hat{\theta} \rightarrow \mu$ .

## Intervalos de confianza para $\mu$

- d) Para  $\hat{\theta}$  se determinan  $\hat{\theta}_L$  y  $\hat{\theta}_U$  de modo tal que

$$P \left\{ \hat{\theta}_L < \hat{\theta} < \hat{\theta}_U \right\} = 1 - \alpha, \quad (1)$$

con  $\alpha \in (0, 1)$ . Es decir,  $\theta \in (\hat{\theta}_L, \hat{\theta}_U)$  es un intervalo de confianza del  $100(1 - \alpha) \%$ .

- e) De acuerdo con el TLC se espera que la distribución muestral de  $\bar{X}$  se distribuye aproximadamente normal con media  $\mu_X = \mu$  y desviación estándar  $\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$ .

## Intervalos de confianza para $\mu$

Para  $Z_{\alpha/2}$  se tiene  $P\{-Z_{\alpha/2} < Z < Z_{\alpha/2}\} = 1 - \alpha$ , donde  $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$ . Entonces  $P\{-Z_{\alpha/2} < \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} < Z_{\alpha/2}\} = 1 - \alpha$  es equivalente a  $P\left\{\bar{X} - Z_{\alpha/2} \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + Z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right\} = 1 - \alpha$

- f) Si  $\bar{X}$  es la media muestral de una muestra de tamaño  $n$  de una población con varianza conocida  $\sigma^2$ , el intervalo de confianza de  $100(1 - \alpha) \%$  para  $\mu$  es  $\mu \in \left(\bar{x} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right)$ .
- g) Para muestras pequeñas de poblaciones no normales, no se puede esperar que el grado de confianza sea preciso.
- h) Para  $n \geq 30$ , con distribución de forma no muy sesgada, se pueden tener buenos resultados.

## Intervalos de confianza para $\mu$

### Teorema

*Si  $\bar{X}$  es un estimador de  $\mu$ , podemos tener  $100(1 - \alpha)\%$  de confianza en que el error no excederá a  $z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$ , error entre  $\bar{X}$  y  $\mu$ .*

### Teorema

*Si  $\bar{X}$  es un estimador de  $\mu$ , podemos tener  $100(1 - \alpha)\%$  de confianza en que el error no excederá una cantidad  $e$  cuando el tamaño de la muestra es*

$$n = \left( \frac{z_{\alpha/2} \sigma}{e} \right)^2.$$

### Nota

*Para intervalos unilaterales*

$$P \left\{ \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} < z_{\alpha} \right\} = 1 - \alpha$$

## Intervalos de confianza para $\mu$

equivalentemente

$$P \left\{ \mu < \bar{X} + Z_{\alpha} \frac{\sigma}{\sqrt{n}} \right\} = 1 - \alpha.$$

Si  $\bar{X}$  es la media de una muestra aleatoria de tamaño  $n$  a partir de una población con varianza  $\sigma^2$ , los límites de confianza unilaterales del  $100(1 - \alpha)\%$  de confianza para  $\mu$  están dados por

- Límite unilateral superior:  $\bar{x} + z_{\alpha} \frac{\sigma}{\sqrt{n}}$
- Límite unilateral inferior:  $\bar{x} - z_{\alpha} \frac{\sigma}{\sqrt{n}}$

## Intervalos de confianza para $\mu$

- Para  $\sigma$  desconocida recordar que  $T = \frac{\bar{X} - \mu}{s/\sqrt{n}} \sim t_{n-1}$ , donde  $s$  es la desviación estándar de la muestra. Entonces

$$P \left\{ -t_{\alpha/2} < T < t_{\alpha/2} \right\} = 1 - \alpha, \text{ equivalentemente}$$

$$P \left\{ \bar{X} - t_{\alpha/2} \frac{s}{\sqrt{n}} < \mu < \bar{X} + t_{\alpha/2} \frac{s}{\sqrt{n}} \right\} = 1 - \alpha.$$

- Un intervalo de confianza del  $100(1 - \alpha) \%$  de confianza para  $\mu$ ,  $\sigma^2$  desconocida y población normal es  $\mu \in \left( \bar{X} - t_{\alpha/2} \frac{s}{\sqrt{n}}, \bar{X} + t_{\alpha/2} \frac{s}{\sqrt{n}} \right)$ , donde  $t_{\alpha/2}$  es una  $t$ -student con  $\nu = n - 1$  grados de libertad.
- Los límites unilaterales para  $\mu$  con  $\sigma$  desconocida son  $\bar{X} - t_{\alpha/2} \frac{s}{\sqrt{n}}$  y  $\bar{X} + t_{\alpha/2} \frac{s}{\sqrt{n}}$ .



## Intervalos de confianza para $\mu$

- Cuando la población no es normal,  $\sigma$  desconocida y  $n \geq 30$ ,  $\sigma$  se puede reemplazar por  $s$  para obtener el intervalo de confianza para muestras grandes:

$$\bar{X} \pm t_{\alpha/2} \frac{s}{\sqrt{n}}.$$

- El estimador de  $\bar{X}$  de  $\mu$ ,  $\sigma$  desconocida, la varianza de  $\sigma_{\bar{X}}^2 = \frac{\sigma^2}{n}$ , el error estándar de  $\bar{X}$  es  $\sigma/\sqrt{n}$ .
- Si  $\sigma$  es desconocida y la población es normal,  $s \rightarrow \sigma$  y se incluye el error estándar  $s/\sqrt{n}$ , entonces

$$\bar{x} \pm t_{\alpha/2} \frac{s}{\sqrt{n}}.$$

## Intervalos de confianza para $\sigma^2$

Supongamos que  $X$  se distribuye normal  $(\mu, \sigma^2)$ , desconocidas. Sea  $X_1, X_2, \dots, X_n$  muestra aleatoria de tamaño  $n$ ,  $s^2$  la varianza muestral.

Se sabe que  $X^2 = \frac{(n-1)s^2}{\sigma^2}$  se distribuye  $\chi_{n-1}^2$  grados de libertad. Su intervalo de confianza es

$$\begin{aligned} P \left\{ \chi_{1-\frac{\alpha}{2}, n-1}^2 \leq \chi^2 \leq \chi_{\frac{\alpha}{2}, n-1}^2 \right\} &= 1 - \alpha \\ P \left\{ \chi_{1-\frac{\alpha}{2}, n-1}^2 \leq \frac{(n-1)s^2}{\sigma^2} \leq \chi_{\frac{\alpha}{2}, n-1}^2 \right\} &= 1 - \alpha \\ P \left\{ \frac{(n-1)s^2}{\chi_{\frac{\alpha}{2}, n-1}^2} \leq \sigma^2 \leq \frac{(n-1)s^2}{\chi_{1-\frac{\alpha}{2}, n-1}^2} \right\} &= 1 - \alpha \end{aligned} \quad (2)$$

es decir

## Intervalos de confianza para $\sigma^2$

$$\sigma^2 \in \left[ \frac{(n-1)s^2}{\chi_{\frac{\alpha}{2}, n-1}^2}, \frac{(n-1)s^2}{\chi_{1-\frac{\alpha}{2}, n-1}^2} \right] \quad (3)$$

los intervalos unilaterales son

$$\sigma^2 \in \left[ \frac{(n-1)s^2}{\chi_{\frac{\alpha}{2}, n-1}^2}, \infty \right) - \quad (4)$$

$$\sigma^2 \in \left[ -\infty, \frac{(n-1)s^2}{\chi_{1-\frac{\alpha}{2}, n-1}^2} \right] \quad (5)$$

## Intervalos de confianza para proporciones

Supongamos que se tienen una muestra de tamaño  $n$  de una población grande pero finita, y supongamos que  $X$ ,  $X \leq n$ , pertenecen a la clase de interés, entonces

$$\hat{p} = \frac{\overline{X}}{n}$$

es el estimador puntual de la proporción de la población que pertenece a dicha clase.

$n$  y  $p$  son los parámetros de la distribución binomial, entonces

$\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right)$  aproximadamente si  $p$  es distinto de 0 y 1; o si  $n$  es suficientemente grande. Entonces

$$Z = \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \sim N(0, 1), \text{ aproximadamente.}$$

## Intervalos de confianza para proporciones

entonces

$$\begin{aligned} 1 - \alpha &= P \left\{ -z_{\alpha/2} \leq \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \leq z_{\alpha/2} \right\} \\ &= P \left\{ \hat{p} - z_{\alpha/2} \sqrt{\frac{p(1-p)}{n}} \leq p \leq \hat{p} + z_{\alpha/2} \sqrt{\frac{p(1-p)}{n}} \right\} \end{aligned}$$

con  $\sqrt{\frac{p(1-p)}{n}}$  error estándar del estimador puntual  $p$ . Una solución para determinar el intervalo de confianza del parámetro  $p$  (desconocido) es

## Intervalos de confianza para proporciones

$$1 - \alpha = P \left\{ \hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \leq p \leq \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \right\}$$

entonces los intervalos de confianza, tanto unilaterales como de dos colas son:

- $p \in \left( \hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}, \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \right)$
- $p \in \left( -\infty, \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \right)$
- $p \in \left( \hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}, \infty \right)$

para minimizar el error estándar, se propone que el tamaño de la muestra sea  $n = \left( \frac{z_{\alpha/2}}{E} \right)^2 p(1 - p)$ , donde  $E = |p - \hat{p}|$ .

## Varianzas Conocidas

Sean  $X_1$  y  $X_2$  variables aleatorias independientes.  $X_1$  con media desconocida  $\mu_1$  y varianza conocida  $\sigma_1^2$ ; y  $X_2$  con media desconocida  $\mu_2$  y varianza conocida  $\sigma_2^2$ . Se busca encontrar un intervalo de confianza de  $100(1 - \alpha) \%$  de la diferencia entre medias  $\mu_1$  y  $\mu_2$ .

Sean  $X_{11}, X_{12}, \dots, X_{1n_1}$  muestra aleatoria de  $n_1$  observaciones de  $X_1$ , y sean  $X_{21}, X_{22}, \dots, X_{2n_2}$  muestra aleatoria de  $n_2$  observaciones de  $X_2$ .

Sean  $\bar{X}_1$  y  $\bar{X}_2$ , medias muestrales, entonces el estadístico

$$Z = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1), \quad (6)$$

si  $X_1$  y  $X_2$  son normales o aproximadamente normales si se aplican las condiciones del Teorema de Límite Central respectivamente.

## Varianzas conocidas

Entonces se tiene

$$\begin{aligned}1 - \alpha &= P \left\{ -Z_{\alpha/2} \leq Z \leq Z_{\alpha/2} \right\} \\&= P \left\{ -Z_{\alpha/2} \leq \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \leq Z_{\alpha/2} \right\} \\&= P \left\{ (\bar{X}_1 - \bar{X}_2) - Z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \leq \mu_1 - \mu_2 \leq \right. \\&\quad \left. (\bar{X}_1 - \bar{X}_2) + Z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right\}\end{aligned}$$



## Varianzas conocidas

Entonces los intervalos de confianza unilaterales y de dos colas al  $(1 - \alpha)$  % de confianza son

- $\mu_1 - \mu_2 \in \left[ (\bar{X}_1 - \bar{X}_2) - Z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, (\bar{X}_1 - \bar{X}_2) + Z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right]$
- $\mu_1 - \mu_2 \in \left[ -\infty, (\bar{X}_1 - \bar{X}_2) + Z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right]$
- $\mu_1 - \mu_2 \in \left[ (\bar{X}_1 - \bar{X}_2) - Z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, \infty \right]$

## Varianzas conocidas

### Nota

*Si  $\sigma_1$  y  $\sigma_2$  son conocidas, o por lo menos se conoce una aproximación, y los tamaños de las muestras  $n_1$  y  $n_2$  son iguales,  $n_1 = n_2 = n$ , se puede determinar el tamaño de la muestra para que el error al estimar  $\mu_1 - \mu_2$  usando  $\bar{X}_1 - \bar{X}_2$  sea menor que  $E$  (valor del error deseado) al  $(1 - \alpha)$  % de confianza. El tamaño  $n$  de la muestra requerido para cada muestra es*

$$n = \left( \frac{Z_{\alpha/2}}{E} \right)^2 (\sigma_1^2 + \sigma_2^2).$$

## Varianzas desconocidas

- Si  $n_1, n_2 \geq 30$  se pueden utilizar los intervalos de la distribución normal para varianzas conocida
- Si  $n_1, n_2$  son muestras pequeñas, supongase que las poblaciones para  $X_1$  y  $X_2$  son normales con varianzas desconocidas y con base en el intervalo de confianza para distribuciones  $t$ -student

$$\sigma_1^2 = \sigma_2^2 = \sigma$$

Supongamos que  $X_1$  es una variable aleatoria con media  $\mu_1$  y varianza  $\sigma_1^2$ ,  $X_2$  es una variable aleatoria con media  $\mu_2$  y varianza  $\sigma_2^2$ . Todos los parámetros son desconocidos. Sin embargo supóngase que es razonable considerar que  $\sigma_1^2 = \sigma_2^2 = \sigma^2$ .

Nuevamente sean  $X_1$  y  $X_2$  variables aleatorias independientes.  $X_1$  con media desconocida  $\mu_1$  y varianza muestral  $S_1^2$ ; y  $X_2$  con media desconocida  $\mu_2$  y varianza muestral  $S_2^2$ . Dado que  $S_1^2$  y  $S_2^2$  son estimadores de  $\sigma_1^2$ , se propone el estimador  $S$  de  $\sigma^2$  como

$$S_p^2 = \frac{(n_1 - 1) S_1^2 + (n_2 - 1) S_2^2}{n_1 + n_2 - 2},$$

entonces, el estadístico para  $\mu_1 - \mu_2$  es

$$\sigma_1^2 = \sigma_2^2 = \sigma$$

$$t_\nu = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

donde  $t_\nu$  es una  $t$  de student con  $\nu = n_1 + n_2 - 2$  grados de libertad.

Por lo tanto

$$\begin{aligned} 1 - \alpha &= P \left\{ -t_{\alpha/2, \nu} \leq t \leq t_{\alpha/2, \nu} \right\} \\ &= P \left\{ (\bar{X}_1 - \bar{X}_2) - t_{\alpha/2, \nu} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \leq \right. \\ &\quad \left. t \leq (\bar{X}_1 - \bar{X}_2) + t_{\alpha/2, \nu} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right\} \end{aligned}$$

$$\sigma_1^2 = \sigma_2^2 = \sigma$$

luego, los intervalos de confianza del  $(1 - \alpha) \%$  para  $\mu_1 - \mu_2$  son

- $\mu_1 - \mu_2 \in \left[ (\bar{X}_1 - \bar{X}_2) - t_{\alpha/2, \nu} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}, (\bar{X}_1 - \bar{X}_2) + t_{\alpha/2, \nu} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right]$
- $\mu_1 - \mu_2 \in \left[ -\infty, (\bar{X}_1 - \bar{X}_2) + t_{\alpha/2, \nu} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right]$
- $\mu_1 - \mu_2 \in \left[ (\bar{X}_1 - \bar{X}_2) - t_{\alpha/2, \nu} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}, \infty \right]$

## Varianzas desconocidas

Si no se tiene certeza de que  $\sigma_1^2 = \sigma_2^2$ , se propone el estadístico

$$t^* = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}} \quad (7)$$

que se distribuye  $t$ -student con  $\nu$  grados de libertad, donde

$$\nu = \frac{\left(\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}\right)^2}{\frac{S_1^2/n_1}{n_1+1} + \frac{S_2^2/n_2}{n_2+1}} - 2$$

## Varianzas desconocidas

Entonces el intervalo de confianza de aproximadamente el  $100(1 - \alpha) \%$  para  $\mu_1 - \mu_2$  con  $\sigma_1^2 \neq \sigma_2^2$  es

$$\mu_1 - \mu_2 \in \left[ (\bar{X}_1 - \bar{X}_2) - t_{\alpha/2, \nu} \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}, \right. \\ \left. (\bar{X}_1 - \bar{X}_2) + t_{\alpha/2, \nu} \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}} \right]$$



## Cociente de Varianzas

Supongamos que se toman dos muestras aleatorias independientes de las dos poblaciones de interés.

Sean  $X_1$  y  $X_2$  variables normales independientes con medias desconocidas  $\mu_1$  y  $\mu_2$  y varianzas desconocidas  $\sigma_1^2$  y  $\sigma_2^2$  respectivamente. Se busca un intervalo de confianza de  $100(1 - \alpha) \%$  para  $\sigma_1^2/\sigma_2^2$ . Supongamos  $n_1$  y  $n_2$  muestras aleatorias de  $X_1$  y  $X_2$  y sean  $S_1^2$  y  $S_2^2$  varianzas muestrales. Se sabe que

$$F = \frac{S_2^2/\sigma_2^2}{S_1^2/\sigma_1^2}$$

se distribuye  $F$  con  $n_2 - 1$  y  $n_1 - 1$  grados de libertad.

## Cociente de Varianzas

Por lo tanto

$$P \left\{ F_{1-\frac{\alpha}{2}, n_2-1, n_1-1} \leq F \leq F_{\frac{\alpha}{2}, n_2-1, n_1-1} \right\} = 1 - \alpha$$
$$P \left\{ F_{1-\frac{\alpha}{2}, n_2-1, n_1-1} \leq \frac{S_2^2/\sigma_2^2}{S_1^2/\sigma_1^2} \leq F_{\frac{\alpha}{2}, n_2-1, n_1-1} \right\} = 1 - \alpha$$

por lo tanto

$$P \left\{ \frac{S_1^2}{S_2^2} F_{1-\frac{\alpha}{2}, n_2-1, n_1-1} \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{S_1^2}{S_2^2} F_{\frac{\alpha}{2}, n_2-1, n_1-1} \right\} = 1 - \alpha$$

entonces

## Cociente de Varianzas

$$\frac{\sigma_1^2}{\sigma_2^2} \in \left[ \frac{S_1^2}{S_2^2} F_{1-\frac{\alpha}{2}, n_2-1, n_1-1}, \frac{S_1^2}{S_2^2} F_{\frac{\alpha}{2}, n_2-1, n_1-1} \right]$$

donde

$$F_{1-\frac{\alpha}{2}, n_2-1, n_1-1} = \frac{1}{F_{\frac{\alpha}{2}, n_2-1, n_1-1}}$$

## Diferencia de Proporciones

Sean dos proporciones de interés  $p_1$  y  $p_2$ . Se busca un intervalo para  $p_1 - p_2$  al  $100(1 - \alpha) \%$ .

Sean dos muestras independientes de tamaño  $n_1$  y  $n_2$  de poblaciones infinitas de modo que  $X_1$  y  $X_2$  variables aleatorias binomiales independientes con parámetros  $(n_1, p_1)$  y  $(n_2, p_2)$ .

$X_1$  y  $X_2$  son el número de observaciones que pertenecen a la clase de interés correspondientes. Entonces  $\hat{p}_1 = \frac{X_1}{n_1}$  y  $\hat{p}_2 = \frac{X_2}{n_2}$  son estimadores de  $p_1$  y  $p_2$  respectivamente. Supongamos que se cumple la aproximación normal a la binomial, entonces

## Diferencia de Proporciones

$$Z = \frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{\sqrt{\frac{p_1(1-p_1)}{n_1} - \frac{p_2(1-p_2)}{n_2}}} \sim N(0, 1) \text{ aproximadamente}$$

entonces

$$\begin{aligned} (\hat{p}_1 - \hat{p}_2) - Z_{\frac{\alpha}{2}} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}} &\leq p_1 - p_2 \\ &\leq (\hat{p}_1 - \hat{p}_2) + Z_{\frac{\alpha}{2}} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} - \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}} \end{aligned}$$

## Lista de Ejercicios

- 1) Del libro Probabilidad y Estadística para Ingeniería de Hines, Montgomery, Goldsman y Borror resolver los siguientes ejercicios: 10-9, 10-10, 10-13, 10-16 y 10-20.
- 2) Realizar un programa en R para cada una de las secciones y subsecciones revisadas en clase, para determinar intervalos de confianza.
- 3) Aplicar los programas elaborados en el ejercicio anterior a la siguiente lista: 10-39, 10-41, 10-45, 10-47, 10-48, 10-50, 10-52, 10-54, 10-56, 10-57, 10-58, 10-65, 10-68, 10-72 y 10-73.
- 4) Elaborar una rutina en R que grafique las siguientes distribuciones, permitiendo variar los parámetros de las distribuciones: Binomial, Uniforme continua, Gamma, Beta, Exponencial, Normal y  $t$ -Student.
- 5) Presentar el primer capítulo del libro del curso en formato *Rnw* con su respectivo archivo *pdf* generado

## Prueba de Hipótesis

- Una hipótesis estadística es una afirmación acerca de la distribución de probabilidad de una variable aleatoria, a menudo involucran uno o más parámetros de la distribución.
- Las hipótesis son afirmaciones respecto a la población o distribución bajo estudio, no en torno a la muestra.
- La mayoría de las veces, la prueba de hipótesis consiste en determinar si la situación experimental ha cambiado
- el interés principal es decidir sobre la veracidad o falsedad de una hipótesis, a este procedimiento se le llama *prueba de hipótesis*.
- Si la información es consistente con la hipótesis, se concluye que esta es verdadera, de lo contrario que con base en la información, es falsa.

# Introducción

Una prueba de hipótesis está formada por cinco partes

- La hipótesis nula, denotada por  $H_0$ .
- La hipótesis alterativa, denorada por  $H_1$ .
- El estadístico de prueba y su valor  $p$ .
- La región de rechazo.
- La conclusión.



# Introducción

## Definición

*Las dos hipótesis en competencias son la **hipótesis alternativa**  $H_1$ , usualmente la que se desea apoyar, y la **hipótesis nula**  $H_0$ , opuesta a  $H_1$ .*

En general, es más fácil presentar evidencia de que  $H_1$  es cierta, que demostrar que  $H_0$  es falsa, es por eso que por lo regular se comienza suponiendo que  $H_0$  es cierta, luego se utilizan los datos de la muestra para decidir si existe evidencia a favor de  $H_1$ , más que a favor de  $H_0$ , así se tienen dos conclusiones:

- Rechazar  $H_0$  y concluir que  $H_1$  es verdadera.
- Aceptar, no rechazar,  $H_0$  como verdadera.

# Introducción

## Ejemplo

*Se desea demostrar que el salario promedio por hora en cierto lugar es distinto de 19usd, que es el promedio nacional. Entonces*

*$H_1 : \mu \neq 19$ , y  $H_0 : \mu = 19$ .*

A esta se le denomina **Prueba de hipótesis de dos colas**.

## Ejemplo

*Un determinado proceso produce un promedio de 5 % de piezas defectuosas. Se está interesado en demostrar que un simple ajuste en una máquina reducirá  $p$ , la proporción de piezas defectuosas producidas en este proceso. Entonces se tiene  $H_0 : p < 0,3$  y  $H_1 : p = 0,03$ . Si se puede rechazar  $H_0$ , se concluye que el proceso ajustado produce menos del 5 % de piezas defectuosas.*

A esta se le denomina **Prueba de hipótesis de una cola**.

# Introducción

La decisión de rechazar o aceptar la hipótesis nula está basada en la información contenida en una muestra proveniente de la población de interés. Esta información tiene estas formas

- **Estadístico de prueba:** un sólo número calculado a partir de la muestra.
- **$p$ -value:** probabilidad calculada a partir del estadístico de prueba.

# Introducción

## Definición

*El  $p$ -value es la probabilidad de observar un estadístico de prueba tanto o más alejado del valor observado, si en realidad  $H_0$  es verdadera. Valores grandes del estadística de prueba y valores pequeños de  $p$  significan que se ha observado un evento muy poco probable, si  $H_0$  en realidad es verdadera.*

Todo el conjunto de valores que puede tomar el estadístico de prueba se divide en dos regiones. Un conjunto, formado de valores que apoyan la hipótesis alternativa y llevan a rechazar  $H_0$ , se denomina **región de rechazo**. El otro, conformado por los valores que sustentan la hipótesis nula, se le denomina **región de aceptación**.

# Introducción

Cuando la región de rechazo está en la cola izquierda de la distribución, la prueba se denomina **prueba lateral izquierda**. Una prueba con región de rechazo en la cola derecha se le llama **prueba lateral derecha**.

Si el estadístico de prueba cae en la región de rechazo, entonces se rechaza  $H_0$ . Si el estadístico de prueba cae en la región de aceptación, entonces la hipótesis nula se acepta o la prueba se juzga como no concluyente.

Dependiendo del nivel de confianza que se desea agregar a las conclusiones de la prueba, y el **nivel de significancia**  $\alpha$ , el riesgo que está dispuesto a correr si se toma una decisión incorrecta.

# Introducción

## Definición

*Un **error de tipo I** para una prueba estadística es el error que se tiene al rechazar la hipótesis nula cuando es verdadera. El **nivel de significancia** para una prueba estadística de hipótesis es*

$$\begin{aligned}\alpha &= P\{\text{error tipo I}\} = P\{\text{rechazar equivocadamente } H_0\} \\ &= P\{\text{rechazar } H_0 \text{ cuando } H_0 \text{ es verdadera}\}\end{aligned}$$

Este valor  $\alpha$  representa el valor máximo de riesgo tolerable de rechazar incorrectamente  $H_0$ . Una vez establecido el nivel de significancia, la región de rechazo se define para poder determinar si se rechaza  $H_0$  con un cierto nivel de confianza.

# Cálculo del valor de $p$

## Definición

*El **valor de  $p$**  ( **$p$ -value**) o nivel de significancia observado de un estadístico de prueba es el valor más pequeño de  $\alpha$  para el cual  $H_0$  se puede rechazar. El riesgo de cometer un error tipo I, si  $H_0$  es rechazada con base en la información que proporciona la muestra.*

## Nota

*Valores pequeños de  $p$  indican que el valor observado del estadístico de prueba se encuentra alejado del valor hipotético de  $\mu$ , es decir se tiene evidencia de que  $H_0$  es falsa y por tanto debe de rechazarse.*

# Cálculo del valor de $p$

## Nota

*Valores grandes de  $p$  indican que el estadístico de prueba observado no está alejado de la medi hipotética y no apoya el rechazo de  $H_0$ .*

## Definición

*Si el valor de  $p$  es menor o igual que el nivel de significancia  $\alpha$ , determinado previamente, entonces  $H_0$  es rechazada y se puede concluir que los resultados son estadísticamente significativos con un nivel de confianza del  $100(1 - \alpha) \%$ .*

Es usual utilizar la siguiente clasificación de resultados



## Cálculo del valor de $p$

$p$	$H_0$	Significativa
$p < 0,01$	Rechazar	Altamente
$0,01 \leq p < 0,05$	Rechazar	Estadísticamente
$0,05 \leq p < 0,1$	No rechazar	Tendencia estadística
$0,1 \leq p$	No rechazar	No son estadísticamente

### Nota

*Para determinar el valor de  $p$ , encontrar el área en la cola después del estadístico de prueba. Si la prueba es de una cola, este es el valor de  $p$ . Si es de dos colas, éste valor encontrado es la mitad del valor de  $p$ . Rechazar  $H_0$  cuando el valor de  $p < \alpha$ .*

## Cálculo del valor de $p$

Hay dos tipos de errores al realizar una prueba de hipótesis

	$H_0$ es Verdadera	$H_0$ es Falsa
Rechazar $H_0$	Error tipo I	✓
Aceptar $H_0$	✓	Error tipo II

### Definición

*La probabilidad de cometer el error tipo II se define por  $\beta$  donde*

$$\begin{aligned}\beta &= P\{\text{error tipo II}\} = P\{\text{Aceptar equivocadamente } H_0\} \\ &= P\{\text{Aceptar } H_0 \text{ cuando } H_0 \text{ es falsa}\}\end{aligned}$$

# Potencia de la prueba

## Nota

*Cuando  $H_0$  es falsa y  $H_1$  es verdadera, no siempre es posible especificar un valor exacto de  $\mu$ , sino más bien un rango de posibles valores. En lugar de arriesgarse a tomar una decisión incorrecta, es mejor concluir que no hay evidencia suficiente para rechazar  $H_0$ , es decir en lugar de aceptar  $H_0$ , no rechazar  $H_0$ .*

## Potencia de la prueba

La bondad de una prueba estadística se mide por el tamaño de  $\alpha$  y  $\beta$ , ambas deben de ser pequeñas. Una manera muy efectiva de medir la potencia de la prueba es calculando el complemento del error tipo II:

$$\begin{aligned}1 - \beta &= P\{\text{Rechazar } H_0 \text{ cuando } H_0 \text{ es falsa}\} \\ &= P\{\text{Rechazar } H_0 \text{ cuando } H_1 \text{ es verdadera}\}\end{aligned}$$

### Definición

*La **potencia de la prueba**,  $1 - \beta$ , mide la capacidad de que la prueba funciona como se necesita.*

## Ejemplo ilustrativo

### Ejemplo

*La producción diaria de una planta química local ha promediado 880 toneladas en los últimos años. A la gerente de control de calidad le gustaría saber si este promedio ha cambiado en meses recientes. Ella selecciona al azar 50 días de la base de datos computarizada y calcula el promedio y la desviación estándar de las  $n = 50$  producciones como  $\bar{x} = 871$  toneladas y  $s = 21$  toneladas, respectivamente. Pruebe la hipótesis apropiada usando  $\alpha = 0,05$ .*

## Ejemplo ilustrativo

### Solución

*La hipótesis nula apropiada es:*

## Ejemplo ilustrativo

### Solución

*La hipótesis nula apropiada es:*

$$H_0 : \mu = 880$$

*y la hipótesis alternativa  $H_1$  es*

## Ejemplo ilustrativo

### Solución

*La hipótesis nula apropiada es:*

$$H_0 : \mu = 880$$

*y la hipótesis alternativa  $H_1$  es*

$$H_1 : \mu \neq 880$$

*el estimador puntual para  $\mu$  es  $\bar{x}$ , entonces el estadístico de prueba es*

$$z = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$



## Ejemplo ilustrativo

### Solución

*La hipótesis nula apropiada es:*

$$H_0 : \mu = 880$$

*y la hipótesis alternativa  $H_1$  es*

$$H_1 : \mu \neq 880$$

*el estimador puntual para  $\mu$  es  $\bar{x}$ , entonces el estadístico de prueba es*

$$\begin{aligned} z &= \frac{\bar{x} - \mu_0}{s/\sqrt{n}} \\ &= \frac{871 - 880}{21/\sqrt{50}} = -3,03 \end{aligned}$$

# Ejemplo ilustrativo

## Solución

*Para esta prueba de*

## Ejemplo ilustrativo

### Solución

*Para esta prueba de dos colas, hay que determinar los dos valores de  $z_{\alpha/2}$ , es decir,*

## Ejemplo ilustrativo

### Solución

*Para esta prueba de dos colas, hay que determinar los dos valores de  $z_{\alpha/2}$ , es decir,  $z_{\alpha/2} = \pm 1,96$ , como  $z > z_{\alpha/2}$ ,  $z$*

## Ejemplo ilustrativo

### Solución

*Para esta prueba de dos colas, hay que determinar los dos valores de  $z_{\alpha/2}$ , es decir,  $z_{\alpha/2} = \pm 1,96$ , como  $z > z_{\alpha/2}$ ,  $z$  cae en la zona de rechazo, por lo tanto*

## Ejemplo ilustrativo

### Solución

*Para esta prueba de dos colas, hay que determinar los dos valores de  $z_{\alpha/2}$ , es decir,  $z_{\alpha/2} = \pm 1,96$ , como  $z > z_{\alpha/2}$ ,  $z$  cae en la zona de rechazo, por lo tanto la gerente puede rechazar la hipótesis nula y concluir que el promedio efectivamente ha cambiado.*

## Ejemplo ilustrativo

### Solución

*Para esta prueba de dos colas, hay que determinar los dos valores de  $z_{\alpha/2}$ , es decir,  $z_{\alpha/2} = \pm 1,96$ , como  $z > z_{\alpha/2}$ ,  $z$  cae en la zona de rechazo, por lo tanto la gerente puede rechazar la hipótesis nula y concluir que el promedio efectivamente ha cambiado. La probabilidad de rechazar  $H_0$  cuando esta es verdadera es de*

## Ejemplo ilustrativo

### Solución

*Para esta prueba de dos colas, hay que determinar los dos valores de  $z_{\alpha/2}$ , es decir,  $z_{\alpha/2} = \pm 1,96$ , como  $z > z_{\alpha/2}$ ,  $z$  cae en la zona de rechazo, por lo tanto la gerente puede rechazar la hipótesis nula y concluir que el promedio efectivamente ha cambiado. La*

*probabilidad de rechazar  $H_0$  cuando esta es verdadera es de 0,05. Recordemos que el valor observado del estadístico de prueba es  $z = -3,03$ , la región de rechazo más pequeña que puede usarse y todavía seguir rechazando  $H_0$  es  $|z| > 3,03$ ,*



## Ejemplo ilustrativo

### Solución

*Para esta prueba de dos colas, hay que determinar los dos valores de  $z_{\alpha/2}$ , es decir,  $z_{\alpha/2} = \pm 1,96$ , como  $z > z_{\alpha/2}$ ,  $z$  cae en la zona de rechazo, por lo tanto la gerente puede rechazar la hipótesis nula y concluir que el promedio efectivamente ha cambiado. La*

*probabilidad de rechazar  $H_0$  cuando esta es verdadera es de 0,05. Recordemos que el valor observado del estadístico de prueba es  $z = -3,03$ , la región de rechazo más pequeña que puede usarse y todavía seguir rechazando  $H_0$  es  $|z| > 3,03$ , entonces  $p = 2(0,012) = 0,0024$ , que a su vez es menor que el nivel de significancia  $\alpha$  asignado inicialmente, y además los resultados son*

## Ejemplo ilustrativo

### Solución

*Para esta prueba de dos colas, hay que determinar los dos valores de  $z_{\alpha/2}$ , es decir,  $z_{\alpha/2} = \pm 1,96$ , como  $z > z_{\alpha/2}$ ,  $z$  cae en la zona de rechazo, por lo tanto la gerente puede rechazar la hipótesis nula y concluir que el promedio efectivamente ha cambiado. La*

*probabilidad de rechazar  $H_0$  cuando esta es verdadera es de 0,05. Recordemos que el valor observado del estadístico de prueba es  $z = -3,03$ , la región de rechazo más pequeña que puede usarse y todavía seguir rechazando  $H_0$  es  $|z| > 3,03$ , entonces  $p = 2(0,012) = 0,0024$ , que a su vez es menor que el nivel de significancia  $\alpha$  asignado inicialmente, y además los resultados son **altamente significativos**.*

## Ejemplo ilustrativo

Finalmente determinemos la potencia de la prueba cuando  $\mu$  en realidad es igual a 870 toneladas.

Recordar que la región de aceptación está entre  $-1,96$  y  $1,96$ , para  $\mu = 880$ , equivalentemente

$$874,18 < \bar{x} < 885,82$$

$\beta$  es la probabilidad de aceptar  $H_0$  cuando  $\mu = 870$ , calculemos los valores de  $z$  correspondientes a 874,18 y 885,82

## Ejemplo ilustrativo

Finalmente determinemos la potencia de la prueba cuando  $\mu$  en realidad es igual a 870 toneladas.

Recordar que la región de aceptación está entre  $-1,96$  y  $1,96$ , para  $\mu = 880$ , equivalentemente

$$874,18 < \bar{x} < 885,82$$

$\beta$  es la probabilidad de aceptar  $H_0$  cuando  $\mu = 870$ , calculemos los valores de  $z$  correspondientes a 874,18 y 885,82 Entonces

$$\begin{aligned} z_1 &= \frac{\bar{x} - \mu}{s/\sqrt{n}} = \frac{874,18 - 870}{21/\sqrt{50}} = 1,41 \\ z_2 &= \frac{\bar{x} - \mu}{s/\sqrt{n}} = \frac{885,82 - 870}{21/\sqrt{50}} = 5,33 \end{aligned}$$

## Ejemplo ilustrativo

por lo tanto

$$\begin{aligned}\beta &= P \{ \text{aceptar } H_0 \text{ cuando } H_0 \text{ es falsa} \} \\ &= P \{ 874,18 < \mu < 885,82 \text{ cuando } \mu = 870 \} \\ &= P \{ 1,41 < z < 5,33 \} = P \{ 1,41 < z \} \\ &= 1 - 0,9207 = 0,0793\end{aligned}$$

entonces, la potencia de la prueba es

$$1 - \beta = 1 - 0,0793 = 0,9207$$

que es la probabilidad de rechazar correctamente  $H_0$  cuando  $H_0$  es falsa.

## Ejemplo ilustrativo

Determinar la potencia de la prueba para distintos valores de  $H_1$  y graficarlos, *curva de potencia*

$H_1$	$(1 - \beta)$
865	
870	
872	
875	
877	
880	
883	
885	
888	
890	
895	

## List de Ejercicios

- 1 Encontrar las regiones de rechazo para el estadístico  $z$ , para una prueba de
  - a) dos colas para  $\alpha = 0,01, 0,05, 0,1$
  - b) una cola superior para  $\alpha = 0,01, 0,05, 0,1$
  - c) una cola inferior para  $\alpha = 0,01, 0,05, 0,1$
- 2 Suponga que el valor del estadístico de prueba es
  - a)  $z = -2,41$ , sacar las conclusiones correspondientes para los incisos anteriores.
  - b)  $z = 2,16$ , sacar las conclusiones correspondientes para los incisos anteriores.
  - c)  $z = 1,15$ , sacar las conclusiones correspondientes para los incisos anteriores.
  - d)  $z = -2,78$ , sacar las conclusiones correspondientes para los incisos anteriores.
  - e)  $z = -1,81$ , sacar las conclusiones correspondientes para los incisos anteriores.

## List de Ejercicios

3. Encuentre el valor de  $p$  para las pruebas de hipótesis correspondientes a los valores de  $z$  del ejercicio anterior.
4. Para las pruebas dadas en el ejercicio 2, utilice el valor de  $p$ , determinado en el ejercicio 3, para determinar la significancia de los resultados.



## Lista de Ejercicios

5. Una muestra aleatoria de  $n = 45$  observaciones de una población con media  $\bar{x} = 2,4$ , y desviación estándar  $s = 0,29$ . Suponga que el objetivo es demostrar que la media poblacional  $\mu$  excede 2,3.
- a) Defina la hipótesis nula y alternativa para la prueba.
  - b) Determine la región de rechazo para un nivel de significancia de:  $\alpha = 0,1, 0,05, 0,01$ .
  - c) Determine el error estándar de la media muestral.
  - d) Calcule el valor de  $p$  para los estadísticos de prueba definidos en los incisos anteriores.
  - e) Utilice el valor de  $p$  para sacar una conclusión al nivel de significancia  $\alpha$ .
  - f) Determine el valor de  $\beta$  cuando  $\mu = 2,5$
  - g) Graficar la curva de potencia para la prueba.

## Diferencia entre dos medias poblacionales

El estadístico que resume la información muestral respecto a la diferencia en medias poblacionales ( $\mu_1 - \mu_2$ ) es la diferencia de las medias muestrales ( $\bar{x}_1 - \bar{x}_2$ ), por tanto al probar la diferencia entre las medias muestrales se verifica que la diferencia real entre las medias poblacionales difiere de un valor especificado,  $(\mu_1 - \mu_2) = D_0$ , se puede usar el error estándar de  $(\bar{x}_1 - \bar{x}_2)$ , es decir

$$\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$$

cuyo estimador está dado por

$$SE = \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

# Diferencia entre dos medias poblacionales

El procedimiento para muestras grandes es:

1) **Hipótesis Nula**  $H_0 : (\mu_1 - \mu_2) = D_0$ ,

# Diferencia entre dos medias poblacionales

El procedimiento para muestras grandes es:

- 1) **Hipótesis Nula**  $H_0 : (\mu_1 - \mu_2) = D_0$ ,

donde  $D_0$  es el valor, la diferencia, específico que se desea probar. En algunos casos se querrá demostrar que no hay diferencia alguna, es decir  $D_0 = 0$ .

- 2) **Hipótesis Alternativa**

Prueba de una Cola	Prueba de dos colas
$H_1 : (\mu_1 - \mu_2) > D_0$	$H_1 : (\mu_1 - \mu_2) \neq D_0$
$H_1 : (\mu_1 - \mu_2) < D_0$	

## Diferencia entre dos medias poblacionales

3) Estadístico de prueba:

$$z = \frac{(\bar{x}_1 - \bar{x}_2) - D_0}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

4) Región de rechazo: rechazar  $H_0$  cuando

Prueba de una Cola	Prueba de dos colas
$z > z_0$ $z < -z_\alpha$ cuando $H_1 : (\mu_1 - \mu_2) < D_0$ cuando $p < \alpha$	$z > z_{\alpha/2}$ o $z < -z_{\alpha/2}$

## Diferencia entre dos medias poblacionales:Ejemplo

### Ejemplo

*Para determinar si ser propietario de un automóvil afecta el rendimiento académico de un estudiante, se tomaron dos muestras aleatorias de 100 estudiantes varones. El promedio de calificaciones para los  $n_1 = 100$  no propietarios de un auto tuvieron un promedio y varianza de  $\bar{x}_1 = 2,7$  y  $s_1^2 = 0,36$ , respectivamente, mientras que para la segunda muestra con  $n_2 = 100$  propietarios de un auto, se tiene  $\bar{x}_2 = 2,54$  y  $s_2^2 = 0,4$ . Los datos presentan suficiente evidencia para indicar una diferencia en la media en el rendimiento académico entre propietarios y no propietarios de un automóvil? Hacer pruebas para  $\alpha = 0,01, 0,05$  y  $\alpha = 0,1$ .*

None

## Solución

- *Solución utilizando la técnica de regiones de rechazo: realizando las operaciones  $z = 1,84$ , determinar si excede los valores de  $z_{\alpha/2}$ .*
- *Solución utilizando el p-value: Calcular el valor de  $p$ , la probabilidad de que  $z$  sea mayor que  $z = 1,84$  o menor que  $z = -1,84$ , se tiene que  $p = 0,0658$ . Concluir.*

# Pruebas de hipótesis e Intervalos de Confianza

- Si el intervalo de confianza que se construye contiene el valor del parámetro especificado por  $H_0$ , entonces ese valor es uno de los posibles valores del parámetro y  $H_0$  no debe ser rechazada.
- Si el valor hipotético se encuentra fuera de los límites de confianza, la hipótesis nula es rechazada al nivel de significancia  $\alpha$ .



# Lista de Ejercicios

- 1 Del libro Mendenhall resolver los ejercicios 9.18, 9.19 y 9.20(Mendenhall).
- 2 Del libro Mendenhall resolver los ejercicios: 9.23, 9.26 y 9.28.

## Una proporción Binomial

Para una muestra aleatoria de  $n$  intentos idénticos, de una población binomial, la proporción muestral  $\hat{p}$  tiene una distribución aproximadamente normal cuando  $n$  es grande, con media  $p$  y error estándar

$$SE = \sqrt{\frac{pq}{n}}.$$

La prueba de hipótesis de la forma

$$H_0 : p = p_0$$

$$H_1 : p > p_0, \text{ o } p < p_0 \text{ o } p \neq p_0$$

El estadístico de prueba se construye con el mejor estimador de la proporción verdadera,  $\hat{p}$ , con el estadístico de prueba  $z$ , que se distribuye normal estándar.

# Una proporción Binomial

El procedimiento es

- 1) Hipótesis nula:  $H_0 : p = p_0$
- 2) Hipótesis alternativa

Prueba de una Cola	Prueba de dos colas
$H_1 : p > p_0$	$p \neq p_0$
$H_1 : p < p_0$	

- 3) Estadístico de prueba:

$$z = \frac{\hat{p} - p_0}{\sqrt{\frac{pq}{n}}}, \hat{p} = \frac{x}{n}$$

donde  $x$  es el número de éxitos en  $n$  intentos binomiales.

## Una proporción Binomial

4) Región de rechazo: rechazar  $H_0$  cuando

Prueba de una Cola	Prueba de dos colas
$z > z_0$	
$z < -z_\alpha$ cuando $H_1 : p < p_0$ cuando $p < \alpha$	$z > z_{\alpha/2}$ o $z < -z_{\alpha/2}$

# Una proporción Binomial

## Ejemplo

*A cualquier edad, alrededor del 20 % de los adultos de cierto país realiza actividades de acondicionamiento físico al menos dos veces por semana. En una encuesta local de  $n = 100$  adultos de más de 40 años, un total de 15 personas indicaron que realizaron actividad física al menos dos veces por semana. Estos datos indican que el porcentaje de participación para adultos de más de 40 años de edad es considerablemente menor a la cifra del 20 %? Calcule el valor de  $p$  y úselo para sacar las conclusiones apropiadas.*

# Una proporción Binomial

- 1 Resolver los ejercicios: 9.30, 9.32, 9.33, 9.35 y 9.39.

## Dos proporciones binomiales

### Nota

*Cuando se tienen dos muestras aleatorias independientes de dos poblaciones binomiales, el objetivo del experimento puede ser la diferencia  $(p_1 - p_2)$  en las proporciones de individuos u objetos que poseen una característica específica en las dos poblaciones. En este caso se pueden utilizar los estimadores de las dos proporciones  $(\hat{p}_1 - \hat{p}_2)$  con error estándar dado por*

$$SE = \sqrt{\frac{p_1 q_1}{n_1} + \frac{p_2 q_2}{n_2}}$$

*considerando el estadístico z con un nivel de significancia  $(1 - \alpha) 100 \%$*

# Dos proporciones binomiales

## Nota

*La hipótesis nula a probarse es de la forma*

*$H_0: p_1 = p_2$  o equivalentemente  $(p_1 - p_2) = 0$ , contra una hipótesis alternativa  $H_1$  de una o dos colas.*

## Nota

*Para estimar el error estándar del estadístico  $z$ , se debe de utilizar el hecho de que suponiendo que  $H_0$  es verdadera, las dos proporciones son iguales a algún valor común,  $p$ . Para obtener el mejor estimador de  $p$  es*

$$p = \frac{\text{número total de éxitos}}{\text{Número total de pruebas}} = \frac{x_1 + x_2}{n_1 + n_2}$$



## Prueba de Hipótesis para $(p_1 - p_2)$

1) **Hipótesis Nula:**  $H_0 : (p_1 - p_2) = 0$

2) **Hipótesis Alternativa:**  $H_1 :$

Prueba de una Cola	Prueba de dos colas
$H_1 : (p_1 - p_2) > 0$	$H_1 : (p_1 - p_2) \neq 0$
$H_1 : (p_1 - p_2) < 0$	

3) **Estadístico de prueba:**

$$z = \frac{(\hat{p}_1 - \hat{p}_2)}{\sqrt{\frac{p_1 q_1}{n_1} + \frac{p_2 q_2}{n_2}}} = \frac{(\hat{p}_1 - \hat{p}_2)}{\sqrt{\frac{pq}{n_1} + \frac{pq}{n_2}}}$$

donde  $\hat{p}_1 = x_1/n_1$  y  $\hat{p}_2 = x_2/n_2$ , dado que el valor común para  $p_1$  y  $p_2$  es  $p$ , entonces  $\hat{p} = \frac{x_1+x_2}{n_1+n_2}$  y por tanto el estadístico de prueba es

## Prueba de Hipótesis para $(p_1 - p_2)$

$$z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}\hat{q}\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}}$$

4) Región de rechazo: rechazar  $H_0$  cuando

Prueba de una Cola	Prueba de dos colas
$z > z_\alpha$	
$z < -z_\alpha$ cuando $H_1 : p < p_0$	$z > z_{\alpha/2}$ o $z < -z_{\alpha/2}$
cuando $p < \alpha$	

## Dos proporciones binomiales: ejercicio

### Ejemplo

*Los registros de un hospital, indican que 52 hombres de una muestra de 1000 contra 23 mujeres de una muestra de 1000 fueron ingresados por enfermedad del corazón. Estos datos presentan suficiente evidencia para indicar un porcentaje más alto de enfermedades del corazón entre hombres ingresados al hospital?, utilizar distintos niveles de confianza de  $\alpha$ .*

- 1 Resolver los ejercicios 9.42
- 2 Resolver los ejercicios: 9.45, 9.48, 9.50

## Una media poblacional

1) Hipótesis Nula:  $H_0 : \mu = \mu_0$

2) Hipótesis Alternativa:  $H_1 :$

Prueba de una Cola	Prueba de dos colas
$H_1 : \mu > \mu_0$	$H_1 : \mu \neq \mu_0$
$H_1 : \mu < \mu_0$	

3) Estadístico de prueba:

$$t = \frac{\bar{x} - \mu_0}{\sqrt{\frac{s^2}{n}}}$$

4) Región de rechazo: rechazar  $H_0$  cuando

Prueba de una Cola	Prueba de dos colas
$t > t_\alpha$	
$t < -t_\alpha$ cuando $H_1 : \mu < \mu_0$	$t > t_{\alpha/2}$ o $t < -t_{\alpha/2}$
cuando $p < \alpha$	

## Ejercicio

### Ejemplo

*Las etiquetas en latas de un gal'on de pintura por lo general indican el tiempo de secado y el área puede cubrir una capa. Casi todas las marcas de pintura indican que, en una capa, un galón cubrirá entre 250 y 500 pies cuadrados, dependiendo de la textura de la superficie a pintarse, un fabricante, sin embargo afirma que un galón de su pintura cubrirá 400 pies cuadrados de área superficial. Para probar su afirmación, una muestra aleatoria de 10 latas de un galón de pintura blanca se empleó para pintar 10 áreas idénticas usando la misma clase de equipo. Las áreas reales en pies cuadrados cubiertas por estos 10 galones de pintura se dan a continuación:*

310	311	412	368	447
376	303	410	365	350

# Ejercicio

## Ejemplo

*Los datos presentan suficiente evidencia para indicar que el promedio de la cobertura difiere de 400 pies cuadrados? encuentre el valor de  $p$  para la prueba y úselo para evaluar la significancia de los resultados.*

- 1 Resolver los ejercicios: 10.2, 10.3, 10.5, 10.7, 10.9, 10.13 y 10.16

## Diferencia entre dos medias: M.A.I.

### Nota

*Cuando los tamaños de muestra son pequeños, no se puede asegurar que las medias muestrales sean normales, pero si las poblaciones originales son normales, entonces la distribución muestral de la diferencia de las medias muestrales,  $(\bar{x}_1 - \bar{x}_2)$ , será normal con media  $(\mu_1 - \mu_2)$  y error estándar*

$$ES = \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$$

## Diferencia entre dos medias: M.A.I.

1) **Hipótesis Nula**  $H_0 : (\mu_1 - \mu_2) = D_0,$



## Diferencia entre dos medias: M.A.I.

### 1) Hipótesis Nula $H_0 : (\mu_1 - \mu_2) = D_0$ ,

donde  $D_0$  es el valor, la diferencia, específico que se desea probar. En algunos casos se querrá demostrar que no hay diferencia alguna, es decir  $D_0 = 0$ .

### 2) Hipótesis Alternativa

Prueba de una Cola	Prueba de dos colas
$H_1 : (\mu_1 - \mu_2) > D_0$	$H_1 : (\mu_1 - \mu_2) \neq D_0$
$H_1 : (\mu_1 - \mu_2) < D_0$	

### 3) Estadístico de prueba:

$$t = \frac{(\bar{x}_1 - \bar{x}_2) - D_0}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

## Diferencia entre dos medias: M.A.I.

donde

$$s^2 = \frac{(n_1 - 1) s_1^2 + (n_2 - 1) s_2^2}{n_1 + n_2 - 2}$$

4) Región de rechazo: rechazar  $H_0$  cuando

Prueba de una Cola	Prueba de dos colas
$z > z_0$	
$z < -z_\alpha$ cuando $H_1 : (\mu_1 - \mu_2) < D_0$	$z > z_{\alpha/2}$ o $z < -z_{\alpha/2}$
cuando $p < \alpha$	

Los valores críticos de  $t$ ,  $t_{-\alpha}$  y  $t_{\alpha/2}$  están basados en  $(n_1 + n_2 - 2)$  grados de libertad.

## Diferencias pareadas

1) **Hipótesis Nula:**  $H_0 : \mu_d = 0$

2) **Hipótesis Alternativa:**  $H_1 : \mu_d$

Prueba de una Cola	Prueba de dos colas
$H_1 : \mu_d > 0$	$H_1 : \mu_d \neq 0$
$H_1 : \mu_d < 0$	

3) Estadístico de prueba:

$$t = \frac{\bar{d}}{\sqrt{\frac{s_d^2}{n}}}$$

donde  $n$  es el número de diferencias pareadas,  $\bar{d}$  es la media de las diferencias muestrales, y  $s_d$  es la desviación estándar de las diferencias muestrales.

## Diferencias pareadas

4) Región de rechazo: rechazar  $H_0$  cuando

Prueba de una Cola	Prueba de dos colas
$t > t_\alpha$	
$t < -t_\alpha$ cuando $H_1 : \mu < \mu_0$	$t > t_{\alpha/2}$ o $t < -t_{\alpha/2}$
cuando $p < \alpha$	

Los valores críticos de  $t$ ,  $t_{-\alpha}$  y  $t_{\alpha/2}$  están basados en  $(n_1 + n_2 - 2)$  grados de libertad.

## Varianza poblacional

1) Hipótesis Nula:  $H_0 : \sigma^2 = \sigma_0^2$

2) Hipótesis Alternativa:  $H_1$

Prueba de una Cola	Prueba de dos colas
$H_1 : \sigma^2 > \sigma_0^2$	$H_1 : \sigma^2 \neq \sigma_0^2$
$H_1 : \sigma^2 < \sigma_0^2$	

3) Estadístico de prueba:

$$\chi^2 = \frac{(n-1)s^2}{\sigma_0^2}$$

## Varianza Poblacional

4) Región de rechazo: rechazar  $H_0$  cuando

Prueba de una Cola	Prueba de dos colas
$\chi^2 > \chi^2_{\alpha}$ $\chi^2 < \chi^2_{(1-\alpha)}$ cuando $H_1 : \chi^2 < \chi^2_0$ cuando $p < \alpha$	$\chi^2 > \chi^2_{\alpha/2}$ o $\chi^2 < \chi^2_{(1-\alpha/2)}$

Los valores críticos de  $\chi^2$ , están basados en  $(n_1 + 1)$  grados de libertad.

# Igualdad de dos varianzas

1) Hipótesis Nula  $H_0 : (\sigma_1^2 - \sigma_2^2) = D_0$ ,

# Igualdad de dos varianzas

## 1) Hipótesis Nula $H_0 : (\sigma_1^2 - \sigma_2^2) = D_0$ ,

donde  $D_0$  es el valor, la diferencia, específico que se desea probar. En algunos casos se querrá demostrar que no hay diferencia alguna, es decir  $D_0 = 0$ .

## 2) Hipótesis Alternativa

Prueba de una Cola	Prueba de dos colas
$H_1 : (\sigma_1^2 - \sigma_2^2) > D_0$	$H_1 : (\sigma_1^2 - \sigma_2^2) \neq D_0$
$H_1 : (\sigma_1^2 - \sigma_2^2) < D_0$	



## Diferencia entre dos medias poblacionales

3) Estadístico de prueba:

$$F = \frac{s_1^2}{s_2^2}$$

donde  $s_1^2$  es la varianza muestral más grande.

4) Región de rechazo: rechazar  $H_0$  cuando

Prueba de una Cola	Prueba de dos colas
$F > F_\alpha$	$F > F_{\alpha/2}$
cuando $p < \alpha$	

# Descripción

## Nota

- *En muchos problemas hay dos o más variables relacionadas, para medir el grado de relación se utiliza el **análisis de regresión**.*
- *Supongamos que se tiene una única variable dependiente,  $y$ , y varias variables independientes,  $x_1, x_2, \dots, x_n$ .*
- *La variable  $y$  es una variable aleatoria, y las variables independientes pueden ser distribuidas independiente o conjuntamente.*

- A la relación entre estas variables se le denomina modelo regresión de  $y$  en  $x_1, x_2, \dots, x_n$ , por ejemplo  $y = \phi(x_1, x_2, \dots, x_n)$ , lo que se busca es una función que mejor aproxime a  $\phi(\cdot)$ .

Supongamos que de momento solamente se tienen una variable independiente  $x$ , para la variable de respuesta  $y$ . Y supongamos que la relación que hay entre  $x$  y  $y$  es una línea recta, y que para cada observación de  $x$ ,  $y$  es una variable aleatoria.

El valor esperado de  $y$  para cada valor de  $x$  es

$$E(y|x) = \beta_0 + \beta_1 x \quad (8)$$

$\beta_0$  es la ordenada al origen y  $\beta_1$  la pendiente de la recta en cuestión, ambas constantes desconocidas.

# Mínimos Cuadrados

Supongamos que cada observación  $y$  se puede describir por el modelo

$$y = \beta_0 + \beta_1 x + \epsilon \quad (9)$$

donde  $\epsilon$  es un error aleatorio con media cero y varianza  $\sigma^2$ . Para cada valor  $y_i$  se tiene  $\epsilon_i$  variables aleatorias no correlacionadas, cuando se incluyen en el modelo 9, este se le llama *modelo de regresión lineal simple*.

Suponga que se tienen  $n$  pares de observaciones  $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ , estos datos pueden utilizarse para estimar los valores de  $\beta_0$  y  $\beta_1$ . Esta estimación es por el **métodos de mínimos cuadrados**.

## Mínimos Cuadrados

Entonces la ecuación 9 se puede reescribir como

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i, \text{ para } i = 1, 2, \dots, n. \quad (10)$$

Si consideramos la suma de los cuadrados de los errores aleatorios, es decir, el cuadrado de la diferencia entre las observaciones con la recta de regresión

$$L = \sum_{i=1}^n \epsilon^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \quad (11)$$

## Mínimos Cuadrados

Para obtener los estimadores por mínimos cuadrados de  $\beta_0$  y  $\beta_1$ ,  $\hat{\beta}_0$  y  $\hat{\beta}_1$ , es preciso calcular las derivadas parciales con respecto a  $\beta_0$  y  $\beta_1$ , igualar a cero y resolver el sistema de ecuaciones lineales resultante:

$$\begin{aligned}\frac{\partial L}{\partial \beta_0} &= 0 \\ \frac{\partial L}{\partial \beta_1} &= 0\end{aligned}$$

evaluando en  $\hat{\beta}_0$  y  $\hat{\beta}_1$ , se tiene

# Mínimos Cuadrados

$$-2 \sum_{i=1}^n \left( y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i \right) = 0$$

$$-2 \sum_{i=1}^n \left( y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i \right) x_i = 0$$

simplificando

$$n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n x_i = \sum_{i=1}^n y_i$$

$$\hat{\beta}_0 \sum_{i=1}^n x_i + \hat{\beta}_1 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i$$

# Mínimos Cuadrados

Las ecuaciones anteriores se les denominan *ecuaciones normales de mínimos cuadrados* con solución

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \quad (12)$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i - \frac{1}{n} (\sum_{i=1}^n y_i) (\sum_{i=1}^n x_i)}{\sum_{i=1}^n x_i^2 - \frac{1}{n} (\sum_{i=1}^n x_i)^2} \quad (13)$$

entonces el modelo de regresión lineal simple ajustado es

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x \quad (14)$$



## Mínimos Cuadrados

Se introduce la siguiente notación

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - \frac{1}{n} \left( \sum_{i=1}^n x_i \right)^2 \quad (15)$$

$$S_{xy} = \sum_{i=1}^n y_i (x_i - \bar{x}) = \sum_{i=1}^n x_i y_i - \frac{1}{n} \left( \sum_{i=1}^n x_i \right) \left( \sum_{i=1}^n y_i \right) \quad (16)$$

y por tanto

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} \quad (17)$$

# Propiedades de los estimadores

Nota

# Propiedades de los estimadores

## Nota

- *Las propiedades estadísticas de los estimadores de mínimos cuadrados son útiles para evaluar la suficiencia del modelo.*
- *Dado que  $\hat{\beta}_0$  y  $\hat{\beta}_1$  son combinaciones lineales de las variables aleatorias  $y_i$ , también resultan ser variables aleatorias.*

A saber

$$E(\hat{\beta}_1) = E\left(\frac{S_{xy}}{S_{xx}}\right) = \frac{1}{S_{xx}} E\left(\sum_{i=1}^n y_i (x_i - \bar{x})\right)$$

## Propiedades de los estimadores

$$\begin{aligned} &= \frac{1}{S_{xx}} E \left( \sum_{i=1}^n (\beta_0 + \beta_1 x_i + \epsilon_i) (x_i - \bar{x}) \right) \\ &= \frac{1}{S_{xx}} \left[ \beta_0 E \left( \sum_{k=1}^n (x_k - \bar{x}) \right) + E \left( \beta_1 \sum_{k=1}^n x_k (x_k - \bar{x}) \right) \right. \\ &\quad \left. + E \left( \sum_{k=1}^n \epsilon_k (x_k - \bar{x}) \right) \right] = \frac{1}{S_{xx}} \beta_1 S_{xx} = \beta_1 \end{aligned}$$

por lo tanto

$$E(\hat{\beta}_1) = \beta_1 \quad (18)$$

## Propiedades de los estimadores

### Nota

*Es decir,  $\hat{\beta}_1$  es un estimador insesgado.*

Ahora calculemos la varianza:

$$\begin{aligned}V(\hat{\beta}_1) &= V\left(\frac{S_{xy}}{S_{xx}}\right) = \frac{1}{S_{xx}^2} V\left(\sum_{k=1}^n y_k (x_k - \bar{x})\right) \\&= \frac{1}{S_{xx}^2} \sum_{k=1}^n V(y_k (x_k - \bar{x})) = \frac{1}{S_{xx}^2} \sum_{k=1}^n \sigma^2 (x_k - \bar{x})^2 \\&= \frac{\sigma^2}{S_{xx}^2} \sum_{k=1}^n (x_k - \bar{x})^2 = \frac{\sigma^2}{S_{xx}}\end{aligned}$$

## Propiedades de los estimadores

por lo tanto

$$V(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}} \quad (19)$$

### Proposición

$$E(\hat{\beta}_0) = \beta_0,$$

$$V(\hat{\beta}_0) = \sigma^2 \left( \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right),$$

$$\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = -\frac{\sigma^2 \bar{x}}{S_{xx}}.$$

## Propiedades de los estimadores

Para estimar  $\sigma^2$  es preciso definir la diferencia entre la observación  $y_k$ , y el valor predicho  $\hat{y}_k$ , es decir

$e_k = y_k - \hat{y}_k$ , se le denomina **residuo**.

La suma de los cuadrados de los errores de los residuos, *suma de cuadrados del error*

$$SC_E = \sum_{k=1}^n e_k^2 = \sum_{k=1}^n (y_k - \hat{y}_k)^2 \quad (20)$$

## Propiedades de los estimadores

sustituyendo  $\hat{y}_k = \hat{\beta}_0 + \hat{\beta}_1 x_k$  se obtiene

$$SC_E = \sum_{k=1}^n y_k^2 - n\bar{y}^2 - \hat{\beta}_1 S_{xy} = S_{yy} - \hat{\beta}_1 S_{xy},$$

$$E(SC_E) = (n-2)\sigma^2, \text{ por lo tanto}$$

$$\hat{\sigma}^2 = \frac{SC_E}{n-2} = MC_E \text{ es un estimador insesgado de } \sigma^2.$$



# Prueba de Hipótesis

- Para evaluar la suficiencia del modelo de regresión lineal simple, es necesario llevar a cabo una prueba de hipótesis respecto de los parámetros del modelo así como de la construcción de intervalos de confianza.
- Para poder realizar la prueba de hipótesis sobre la pendiente y la ordenada al origen de la recta de regresión es necesario hacer el supuesto de que el error  $\epsilon_i$  se distribuye normalmente, es decir  $\epsilon_i \sim N(0, \sigma^2)$ .

## Prueba de Hipótesis

Suponga que se desea probar la hipótesis de que la pendiente es igual a una constante,  $\beta_{0,1}$  las hipótesis Nula y Alternativa son:

$$H_0: \beta_1 = \beta_{1,0},$$

$$H_1: \beta_1 \neq \beta_{1,0}.$$

donde dado que las  $\epsilon_i \sim N(0, \sigma^2)$ , se tiene que  $y_i$  son variables aleatorias normales  $N(\beta_0 + \beta_1 x_1, \sigma^2)$ . De las ecuaciones (12) se desprende que  $\hat{\beta}_1$  es combinación lineal de variables aleatorias normales independientes, es decir,  $\hat{\beta}_1 \sim N(\beta_1, \sigma^2/S_{xx})$ , recordar las ecuaciones (18) y (19).

## Prueba de Hipótesis

Entonces se tiene que el estadístico de prueba apropiado es

$$t_0 = \frac{\hat{\beta}_1 - \hat{\beta}_{1,0}}{\sqrt{MC_E/S_{xx}}} \quad (21)$$

que se distribuye  $t$  con  $n - 2$  grados de libertad bajo  $H_0 : \beta_1 = \beta_{1,0}$ . Se rechaza  $H_0$  si

$$|t_0| > t_{\alpha/2, n-2}. \quad (22)$$

## Prueba de Hipótesis

Para  $\beta_0$  se puede proceder de manera análoga para

$$H_0 : \beta_0 = \beta_{0,0},$$

$$H_1 : \beta_0 \neq \beta_{0,0},$$

con  $\hat{\beta}_0 \sim N\left(\beta_0, \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)\right)$ , por lo tanto

$$t_0 = \frac{\hat{\beta}_0 - \beta_{0,0}}{MC_E \left[ \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}, \quad (23)$$

con el que rechazamos la hipótesis nula si

$$|t_0| > t_{\alpha/2, n-2}. \quad (24)$$

## Prueba de Hipótesis

- No rechazar  $H_0 : \beta_1 = 0$  es equivalente a decir que no hay relación lineal entre  $x$  y  $y$ .
- Alternativamente, si  $H_0 : \beta_1 = 0$  se rechaza, esto implica que  $x$  explica la variabilidad de  $y$ , es decir, podríamos significar que la línea recta es el modelo adecuado.

El procedimiento de prueba para  $H_0 : \beta_1 = 0$  puede realizarse de la siguiente manera:

$$S_{yy} = \sum_{k=1}^n (y_k - \bar{y})^2 = \sum_{k=1}^n (\hat{y}_k - \bar{y})^2 + \sum_{k=1}^n (y_k - \hat{y}_k)^2$$

## Prueba de Hipótesis

$$\begin{aligned}S_{yy} &= \sum_{k=1}^n (y_k - \bar{y})^2 = \sum_{k=1}^n (y_k - \hat{y}_k + \hat{y}_k - \bar{y})^2 \\&= \sum_{k=1}^n [(\hat{y}_k - \bar{y}) + (y_k - \hat{y}_k)]^2 \\&= \sum_{k=1}^n \left[ (\hat{y}_k - \bar{y})^2 + 2(\hat{y}_k - \bar{y})(y_k - \hat{y}_k) + (y_k - \hat{y}_k)^2 \right] \\&= \sum_{k=1}^n (\hat{y}_k - \bar{y})^2 + 2 \sum_{k=1}^n (\hat{y}_k - \bar{y})(y_k - \hat{y}_k) + \sum_{k=1}^n (y_k - \hat{y}_k)^2\end{aligned}$$

## Prueba de Hipótesis

$$\begin{aligned} \sum_{k=1}^n (\hat{y}_k - \bar{y}) (y_k - \hat{y}_k) &= \sum_{k=1}^n \hat{y}_k (y_k - \hat{y}_k) - \sum_{k=1}^n \bar{y} (y_k - \hat{y}_k) \\ &= \sum_{k=1}^n \hat{y}_k (y_k - \hat{y}_k) - \bar{y} \sum_{k=1}^n (y_k - \hat{y}_k) \\ &= \sum_{k=1}^n (\hat{\beta}_0 + \hat{\beta}_1 x_k) (y_k - \hat{\beta}_0 - \hat{\beta}_1 x_k) - \bar{y} \sum_{k=1}^n (y_k - \hat{\beta}_0 - \hat{\beta}_1 x_k) \end{aligned}$$

## Prueba de Hipótesis

$$\begin{aligned} &= \sum_{k=1}^n \hat{\beta}_0 (y_k - \hat{\beta}_0 - \hat{\beta}_1 x_k) + \sum_{k=1}^n \hat{\beta}_1 x_k (y_k - \hat{\beta}_0 - \hat{\beta}_1 x_k) \\ &- \bar{y} \sum_{k=1}^n (y_k - \hat{\beta}_0 - \hat{\beta}_1 x_k) \\ &= \hat{\beta}_0 \sum_{k=1}^n (y_k - \hat{\beta}_0 - \hat{\beta}_1 x_k) + \hat{\beta}_1 \sum_{k=1}^n x_k (y_k - \hat{\beta}_0 - \hat{\beta}_1 x_k) \\ &- \bar{y} \sum_{k=1}^n (y_k - \hat{\beta}_0 - \hat{\beta}_1 x_k) = 0 + 0 + 0 = 0. \end{aligned}$$



## Prueba de Hipótesis

Por lo tanto, efectivamente se tiene

$$S_{yy} = \sum_{k=1}^n (\hat{y}_k - \bar{y})^2 + \sum_{k=1}^n (y_k - \hat{y}_k)^2, \quad (25)$$

donde se hacen las definiciones

$$SC_E = \sum_{k=1}^n (\hat{y}_k - \bar{y})^2 \cdots \text{Suma de Cuadrados del Error} \quad (26)$$

$$SC_R = \sum_{k=1}^n (y_k - \hat{y}_k)^2 \cdots \text{Suma de Regresión de Cuadrados} \quad (27)$$

## Prueba de Hipótesis

Por lo tanto la ecuación (25) se puede reescribir como

$$S_{yy} = SC_R + SC_E \quad (28)$$

recordemos que  $SC_E = S_{yy} - \hat{\beta}_1 S_{xy}$

$$S_{yy} = SC_R + (S_{yy} - \hat{\beta}_1 S_{xy})$$

$$S_{xy} = \frac{1}{\hat{\beta}_1} SC_R$$

$S_{xy}$  tiene  $n - 1$  grados de libertad y  $SC_R$  y  $SC_E$  tienen 1 y  $n - 2$  grados de libertad respectivamente.

# Prueba de Hipótesis

## Proposición

$$E(SC_R) = \sigma^2 + \beta_1 S_{xx} \quad (29)$$

además,  $SC_E$  y  $SC_R$  son independientes.

Recordemos que  $\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$ . Para  $H_0 : \beta_1 = 0$  verdadera,

$$F_0 = \frac{SC_R/1}{SC_E/(n-2)} = \frac{MC_R}{MC_E}$$

se distribuye  $F_{1,n-2}$ , y se rechazaría  $H_0$  si  $F_0 > F_{\alpha,1,n-2}$ .

# Prueba de Hipótesis

El procedimiento de prueba de hipótesis puede presentarse como la tabla de análisis de varianza siguiente

Fuente de variación	Suma de Cuadrados	Grados de Libertad	Media Cuadrática	$F_0$
------------------------	----------------------	-----------------------	---------------------	-------

## Prueba de Hipótesis

El procedimiento de prueba de hipótesis puede presentarse como la tabla de análisis de varianza siguiente

Fuente de variación	Suma de Cuadrados	Grados de Libertad	Media Cuadrática	$F_0$
Regresión	$SC_R$	1	$MC_R$	$MC_R/MC_E$

## Prueba de Hipótesis

El procedimiento de prueba de hipótesis puede presentarse como la tabla de análisis de varianza siguiente

Fuente de variación	Suma de Cuadrados	Grados de Libertad	Media Cuadrática	$F_0$
Regresión	$SC_R$	1	$MC_R$	$MC_R/MC_E$
Error Residual	$SC_E$	$n - 2$	$MC_E$	

## Prueba de Hipótesis

El procedimiento de prueba de hipótesis puede presentarse como la tabla de análisis de varianza siguiente

Fuente de variación	Suma de Cuadrados	Grados de Libertad	Media Cuadrática	$F_0$
Regresión	$SC_R$	1	$MC_R$	$MC_R/MC_E$
Error Residual	$SC_E$	$n - 2$	$MC_E$	
Total	$S_{yy}$	$n - 1$		

## Prueba de Hipótesis

La prueba para la significación de la regresión puede desarrollarse basándose en la expresión (21), con  $\hat{\beta}_{1,0} = 0$ , es decir



## Prueba de Hipótesis

La prueba para la significación de la regresión puede desarrollarse basándose en la expresión (21), con  $\hat{\beta}_{1,0} = 0$ , es decir

$$t_0 = \frac{\hat{\beta}_1}{\sqrt{MC_E/S_{xx}}} \quad (30)$$

Elevando al cuadrado ambos términos:

$$t_0^2 = \frac{\hat{\beta}_1^2 S_{xx}}{MC_E} = \frac{\hat{\beta}_1 S_{xy}}{MC_E} = \frac{MC_R}{MC_E}$$

Observar que  $t_0^2 = F_0$ , por tanto la prueba que se utiliza para  $t_0$  es la misma que para  $F_0$ .

# Intervalos de Confianza

- Además de la estimación puntual para los parámetros  $\beta_1$  y  $\beta_0$ , es posible obtener estimaciones del intervalo de confianza de estos parámetros.

# Intervalos de Confianza

- Además de la estimación puntual para los parámetros  $\beta_1$  y  $\beta_0$ , es posible obtener estimaciones del intervalo de confianza de estos parámetros.
- El ancho de estos intervalos de confianza es una medida de la calidad total de la recta de regresión.

## Intervalos de Confianza

Si los  $\epsilon_k$  se distribuyen normal e independientemente, entonces

$$\frac{(\hat{\beta}_1 - \beta_1)}{\sqrt{\frac{MC_E}{S_{xx}}}} \quad y \quad \frac{(\hat{\beta}_0 - \beta_0)}{\sqrt{MC_E \left( \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)}}$$

se distribuyen  $t$  con  $n - 2$  grados de libertad.

## Intervalos de Confianza

Si los  $\epsilon_k$  se distribuyen normal e independientemente, entonces

$$\frac{(\hat{\beta}_1 - \beta_1)}{\sqrt{\frac{MC_E}{S_{xx}}}} \quad y \quad \frac{(\hat{\beta}_0 - \beta_0)}{\sqrt{MC_E \left( \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)}}$$

se distribuyen  $t$  con  $n - 2$  grados de libertad. Por tanto un intervalo de confianza de  $100(1 - \alpha) \%$  para  $\beta_1$  está dado por

## Intervalos de Confianza

$$\hat{\beta}_1 - t_{\alpha/2, n-2} \sqrt{\frac{MCE}{S_{xx}}} \leq \beta_1 \leq \hat{\beta}_1 + t_{\alpha/2, n-2} \sqrt{\frac{MCE}{S_{xx}}}. \quad (31)$$

## Intervalos de Confianza

$$\hat{\beta}_1 - t_{\alpha/2, n-2} \sqrt{\frac{MC_E}{S_{xx}}} \leq \beta_1 \leq \hat{\beta}_1 + t_{\alpha/2, n-2} \sqrt{\frac{MC_E}{S_{xx}}}. \quad (31)$$

De igual manera, para  $\beta_0$  un intervalo de confianza al  $100(1 - \alpha) \%$  es

$$\hat{\beta}_0 - t_{\alpha/2, n-2} \sqrt{MC_E \left( \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)} \leq \beta_0 \leq \hat{\beta}_0 + t_{\alpha/2, n-2} \sqrt{MC_E \left( \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)} \quad (32)$$

## Predicción

Supongamos que se tiene un valor  $x_0$  de interés, entonces la estimación puntual de este nuevo valor

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0 \quad (33)$$

### Nota

*Esta nueva observación es independiente de las utilizadas para obtener el modelo de regresión, por tanto, el intervalo en torno a la recta de regresión es inapropiado, puesto que se basa únicamente en los datos empleados para ajustar el modelo de regresión.*

*El intervalo de confianza en torno a la recta de regresión se refiere a la respuesta media verdadera  $x = x_0$ , no a observaciones futuras.*



## Predicción

Sea  $y_0$  la observación futura en  $x = x_0$ , y sea  $\hat{y}_0$  dada en la ecuación anterior, el estimador de  $y_0$ . Si se define la variable aleatoria

$$w = y_0 - \hat{y}_0,$$

esta se distribuye normalmente con media cero y varianza

$$V(w) = \sigma^2 \left[ 1 + \frac{1}{n} + \frac{(x - x_0)^2}{S_{xx}} \right]$$

dado que  $y_0$  es independiente de  $\hat{y}_0$ , por lo tanto el intervalo de predicción al nivel  $\alpha$  para futuras observaciones  $x_0$  es

## Predicción

$$\begin{aligned} \hat{y}_0 - t_{\alpha/2, n-2} \sqrt{MC_E \left[ 1 + \frac{1}{n} + \frac{(x - x_0)^2}{S_{xx}} \right]} &\leq y_0 \\ &\leq \hat{y}_0 + t_{\alpha/2, n-2} \sqrt{MC_E \left[ 1 + \frac{1}{n} + \frac{(x - x_0)^2}{S_{xx}} \right]}. \end{aligned}$$

## Coeficiente de Determinación

La cantidad

$$R^2 = \frac{SC_R}{S_{yy}} = 1 - \frac{SC_E}{S_{yy}} \quad (34)$$

se denomina coeficiente de determinación y se utiliza para saber si el modelo de regresión es suficiente o no. Se puede demostrar que  $0 \leq R^2 \leq 1$ , una manera de interpretar este valor es que si  $R^2 = k$ , entonces el modelo de regresión explica el  $k * 100 \%$  de la variabilidad en los datos.

# Coeficiente de Determinación

$$R^2$$

- No mide la magnitud de la pendiente de la recta de regresión
- Un valor grande de  $R^2$  no implica una pendiente empinada.
- No mide la suficiencia del modelo.
- Valores grandes de  $R^2$  no implican necesariamente que el modelo de regresión proporcionará predicciones precisas para futuras observaciones.